

**BỘ CÔNG THƯƠNG
TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP HÀ NỘI**



LÊ THỊ LUYỀN

**PHÁT TRIỂN CHATBOT
TRÊN NỀN TẢNG TRANSFORMERS
ỨNG DỤNG TRONG TÌM KIẾM, TRA CỨU THÔNG
TIN VỀ TRƯỜNG ĐẠI HỌC CÔNG NGHỆ ĐÔNG Á**

ĐỀ ÁN TỐT NGHIỆP THẠC SĨ HỆ THỐNG THÔNG TIN

Hà Nội – 2024

**BỘ CÔNG THƯƠNG
TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP HÀ NỘI**



LÊ THỊ LUYÊN

**PHÁT TRIỂN CHATBOT
TRÊN NỀN TẢNG TRANSFORMERS
ỨNG DỤNG TRONG TÌM KIẾM, TRA CỨU THÔNG TIN
VỀ TRƯỜNG ĐẠI HỌC CÔNG NGHỆ ĐÔNG Á**

ĐỀ ÁN TỐT NGHIỆP THẠC SĨ HỆ THỐNG THÔNG TIN

Hà Nội – 2024

**BỘ CÔNG THƯƠNG
TRƯỜNG ĐẠI HỌC CÔNG NGHIỆP HÀ NỘI**



LÊ THỊ LUYÊN

**PHÁT TRIỂN CHATBOT
TRÊN NỀN TẢNG TRANSFORMERS
ỨNG DỤNG TRONG TÌM KIẾM, TRA CỨU THÔNG TIN
VỀ TRƯỜNG ĐẠI HỌC CÔNG NGHỆ ĐÔNG Á**

Ngành: Hệ thống thông tin

Mã số: 8480104

ĐỀ ÁN TỐT NGHIỆP THẠC SĨ HỆ THỐNG THÔNG TIN

NGƯỜI HƯỚNG DẪN:

1. TS. Trần Hùng Cường
2. TS. Đỗ Văn Tuấn

Hà Nội – 2024

LỜI CAM ĐOAN

Tôi xin cam đoan đề án này là công trình nghiên cứu của riêng tôi và những nội dung được trình bày trong đề án này là hoàn toàn trung thực.

Những nội dung trình bày trong đề án này do tôi tìm hiểu, nghiên cứu và trình bày dưới sự hướng dẫn của TS. Trần Hùng Cường và TS. Đỗ Văn Tuấn.

Những số liệu, bảng biểu phục vụ cho việc phân tích và dẫn dắt được thu thập từ các nguồn tài liệu khác nhau được ghi chú trong mục tài liệu tham khảo hoặc chú thích ngay bên dưới các bảng biểu.

Ngoài ra, đối với các tài liệu diễn giải để làm rõ thêm các luận điểm đã phân tích và trích dẫn trong phần phụ lục cũng được chú thích nguồn gốc dữ liệu.

Hà Nội, ngày tháng năm 2024

Học viên thực hiện

LỜI CẢM ƠN

Em xin chân thành cảm ơn TS. Trần Hùng Cường và TS. Đỗ Văn Tuấn đã tin tưởng và cho phép em chọn đề tài “Phát triển ChatBot trên nền tảng Transformers Ứng dụng trong tìm kiếm, tra cứu thông tin về Trường Đại học Công nghệ Đông Á”. Đề tài này đã mang lại cho em nhiều trải nghiệm quý báu cũng như kiến thức vô cùng bổ ích trong lĩnh vực trí tuệ nhân tạo.

Trong quá trình thực hiện đề án, em đã được hỗ trợ nhiệt tình từ các thầy. Những kiến thức, kinh nghiệm cùng những lời khuyên của các thầy đã giúp em hoàn thành đề tài một cách hiệu quả nhất.

Em cũng xin bày tỏ lòng biết ơn sâu sắc đến tập thể giáo viên và những học viên đã giúp đỡ, động viên và cổ vũ em trong suốt quá trình nghiên cứu, thực hiện đề án.

Đề án này không chỉ giúp em nâng cao hiểu biết và kỹ năng nghiên cứu mà còn giúp em có cơ hội thực hành và áp dụng các kiến thức đã học vào thực tế. Em tin rằng những kết quả và kinh nghiệm thu được từ đề án sẽ có giá trị thực tiễn cao và có thể áp dụng được trong công việc của em trong tương lai.

Một lần nữa, em xin chân thành cảm ơn các thầy đã giúp đỡ em trong quá trình nghiên cứu và thực hiện đề án này.

Trân trọng!

Học viên thực hiện

MỤC LỤC

LỜI CAM ĐOAN	i
LỜI CẢM ƠN	ii
MỤC LỤC	iii
DANH MỤC CÁC KÝ HIỆU, CÁC TỪ VIẾT TẮT.....	vi
DANH MỤC CÁC BẢNG	vii
DANH MỤC HÌNH ẢNH.....	viii
MỞ ĐẦU	1
LÝ DO CHỌN ĐỀ TÀI	1
MỤC TIÊU NGHIÊN CỨU	1
PHẠM VI ĐỀ TÀI	2
CHƯƠNG 1 - TỔNG QUAN.....	3
1.1. NHU CẦU TRA CỨU THÔNG TIN THÔNG VỀ TRƯỜNG ĐẠI HỌC CÔNG NGHỆ ĐÔNG Á.....	3
1.1.1. Học sinh, phụ huynh tìm hiểu thông tin về trường	3
1.1.2. Tuyển dụng nhân lực.....	4
1.1.3. Thông tin tuyển dụng, cơ hội nghiên cứu	4
1.1.4. Kết nối cộng đồng sinh viên, cựu sinh viên.....	5
1.2. THỰC TRẠNG, CÁC GIẢI PHÁP ĐANG ĐƯỢC ÁP DỤNG TRONG TRA CỨU THÔNG TIN VỀ TRƯỜNG ĐẠI HỌC CÔNG NGHỆ ĐÔNG Á	5
1.2.1. Trang thông tin điện tử.....	5
1.2.2. Các sự kiện truyền thông.....	5
1.2.3. Mạng xã hội.....	6

1.2.4. Tư vấn học tập, tư vấn tuyển sinh.....	6
1.3. ĐÁNH GIÁ HIỆU QUẢ CỦA CÁC GIẢI PHÁP ĐANG ĐƯỢC ỨNG DỤNG.....	6
1.4. CHATBOT VÀ ỨNG DỤNG CỦA CHATBOT [9]	7
1.4.1. Khái niệm Chatbot	7
1.4.2. Các loại Chatbot.....	8
CHƯƠNG 2 - CƠ SỞ LÝ THUYẾT.....	11
2.1. MẠNG NƠ-RON KẾT NỐI ĐẦY ĐỦ	11
2.1.1. Khái niệm về mạng nơ-ron kết nối đầy đủ.....	13
2.1.2. Hiện tượng overfitting, underfitting và cách khắc phục	14
2.2. MẠNG HỒI QUY VÀ BÀI TOÁN S2S	15
2.2.1. Kiến trúc mạng hồi quy cho bài toán S2S.....	15
2.2.2. Ưu điểm và hạn chế của mạng hồi quy đối với bài toán S2S	16
2.4. TRANSFORMERS	17
2.4.1. Kiến trúc Transformers	17
2.4.2. Mã hóa vị trí của từ	19
2.4.3. Self-Attention và Cross -Attention	19
2.4.4. Một số LLM nổi tiếng sử dụng kiến trúc Transformers	22
2.4.5. Quá trình huấn luyện và đặc trưng của LLMs	27
CHƯƠNG 3 - XÂY DỰNG HỆ THỐNG CHATBOT SỬ DỤNG LLMs	29
3.1. SỰ CẦN THIẾT LOCAL CHATGPT ĐỐI VỚI DOANH NGHIỆP	29
3.2. PHƯƠNG PHÁP HUẤN LUYỆN LLMS	30
3.2.1. Pre-trained	30

3.2.2. Fine-Tuning.....	30
3.2.3. Một số thách thức trong việc huấn luyện LLMs.....	30
3.3. NÂNG CAO HIỆU SUẤT LLMS	31
3.3.1. Tối ưu hóa bộ nhớ LLM bằng kỹ thuật lượng tử	32
3.3.2. Giảm độ phức tạp tính toán bằng kỹ thuật LoRA.....	33
3.3.3. Prompt Engineering	35
3.3.4. VectorDB	38
3.3.5. Kỹ thuật RAG	43
3.3.5.1. Tổng quan.....	43
3.3.5.3. Quá trình hoạt động của RAG	44
3.3.5.4. Ưu điểm của RAG	46
3.4. HỆ THỐNG ĐÔNG Á CHATBOT	47
3.4.1. Thu thập và tiền xử lý dữ liệu	49
3.4.2. Kiến trúc hệ thống ChatBot	52
3.4.3. Kết quả thử nghiệm.....	53
3.4.4. Đánh giá độ chính xác của chatbot	55
KẾT LUẬN	58

DANH MỤC CÁC KÝ HIỆU, CÁC TỪ VIẾT TẮT

Viết tắt	Tiếng Anh	Tiếng Việt
EAUT	East Asia University Of Technology	Đại học Công nghệ Đông Á
AI	Artificial Intelligence	Trí tuệ nhân tạo
SGD	Stochastic gradient descent	Giảm độ dốc ngẫu nhiên
RNN	Recurrent Neural Networks	Mạng nơ-ron hồi quy
CBOW	Continuous Bag-of-Words	Túi từ liên tục
DL	Deep Learning	Học sâu
CPU	Central Processing Unit	Bộ xử lý trung tâm
GPU	Graphics Processing Unit	Bộ xử lý đồ họa
LLM, LLMs	Large Language Model	Mô hình ngôn ngữ lớn
LSTM	Long Short-Term Memory	Mạng bộ nhớ ngắn hạn dài hạn
NLP	Natural Language Processing	Xử lý ngôn ngữ tự nhiên
CNN	Convolutional Neural Networks	Mạng nơ-ron tích chập
UI	User Interface	Giao diện người dùng
RAG	Retrieval-Augmented Generation	Tạo tăng cường truy xuất

DANH MỤC CÁC BẢNG

Bảng 2.1. Cơ sở dữ liệu Pre-trained LLMs.....	27
Bảng 2.2. Các tác vụ thực hiện trong quá trình fine-tuning.....	28

DANH MỤC HÌNH ẢNH

Hình 2.1. Mô hình mạng nơ-ron	12
Hình 2.2. Mạng nơ-ron kết nối đầy đủ.....	14
Hình 2.3. Hàm mục tiêu và overfitting	15
Hình 2.4. Ví dụ mạng nơ-ron hồi quy LSTM	16
Hình 2.5. Các thành phần trong mạng nơ-ron hồi quy LSTM.....	16
Hình 2.6. Sơ đồ mô hình Transformers.....	18
Hình 2.7. Mã hóa vị trí từ nhúng.....	19
Hình 2.8. Cơ chế Self-Attention	20
Hình 2.9. Mô hình BERT	23
Hình 2.10. Mô hình GPT.....	25
Hình 2.11. Mô hình LLaMA	26
Hình 2.12. Quá trình huấn luyện mô hình ngôn ngữ	27
Hình 3.1. Yêu cầu bộ nhớ cho tải và huấn luyện mô hình.....	33
Hình 3.2. Phân rã giá trị số ít của ma trận $m \times n$	34
Hình 3.3. So sánh kỹ thuật huấn luyện LLMs	35
Hình 3.4. Kỹ thuật Zero-shot	37
Hình 3.5. Kỹ thuật Few-shot.....	38
Hình 3.6. Quá trình tạo VectorDB	45
Hình 3.7. Sơ đồ quá trình sử dụng VectorDB.....	45
Hình 3.8. Kiến trúc hệ thống Đông Á Chatbot	53
Hình 3.9. Kết quả câu hỏi về tổ chức lớp sinh viên.....	54
Hình 3.10. Kết quả câu hỏi về ngành công nghệ thông tin của trường	55

MỞ ĐẦU

LÝ DO CHỌN ĐỀ TÀI

Trong thời đại số hóa hiện nay, sự phát triển nhanh chóng của trí tuệ nhân tạo và công nghệ xử lý ngôn ngữ tự nhiên đã tạo ra cơ hội ứng dụng các hệ thống Chatbot thông minh trong nhiều lĩnh vực. Chatbot là một công cụ mạnh mẽ có khả năng tương tác với con người thông qua giao diện ngôn ngữ tự nhiên. Trong lĩnh vực giáo dục, việc phát triển một Chatbot để cung cấp thông tin và giải đáp câu hỏi đang trở thành một ứng dụng quan trọng.

Đại học Công nghệ Đông Á (EAUT) với nhiều nguồn thông tin cần được truy xuất. Một Chatbot có khả năng tra cứu thông tin liên quan đến EAUT sẽ là trợ thủ đắc lực trong công tác truyền thông, cung cấp và giải đáp thông tin về Nhà trường một cách nhanh chóng, chính xác và liên tục. Vấn đề đặt ra là làm thế nào để phát triển một Chatbot thông minh, có khả năng hiểu và phản hồi tự nhiên trong giao tiếp và cung cấp thông tin chính xác về EAUT.

Trước những vấn đề thực tế đó, trong bài luận này, tôi tiến hành nghiên cứu và phát triển một Chatbot dựa trên nền tảng Transformers với mục tiêu cung cấp khả năng hỏi đáp và tra cứu thông tin về Trường Đại học Công Nghệ Đông Á. Bằng cách kết hợp sức mạnh của Transformers – một mô hình học máy tiên tiến và với kiến thức về EAUT, tôi hy vọng tạo ra một công cụ hữu ích và thông minh giúp nâng cao trải nghiệm của cộng đồng EAUT trong việc tra cứu thông tin và tương tác với Nhà trường.

MỤC TIÊU NGHIÊN CỨU

Tìm hiểu và trình bày các khái niệm cơ bản về Chatbot; các kỹ thuật về Deep learning, mô hình Transformers. Khảo sát, đánh giá hiện trạng, nhu cầu truy cập, tìm hiểu và hỏi đáp thông tin về Trường Đại học Công nghệ Đông Á với các giải pháp đang được sử dụng.

Đề tài tập trung vào giải pháp xây dựng hệ thống Chatbot áp dụng Deep learning và mô hình Transformers. Chatbot giúp tra cứu, hỏi đáp thông tin về Trường Đại học Công nghệ Đông Á nhanh hơn, dễ dàng hơn, liên tục và không cần tham gia của con người.

PHẠM VI ĐỀ TÀI

Đề tài này sẽ tập trung vào việc phát triển một chatbot dựa trên nền tảng Transformers với mục tiêu phục vụ hỏi đáp và tra cứu thông tin liên quan đến Trường Đại học Công Nghệ Đông Á. Phạm vi nghiên cứu bao gồm:

Xây dựng mô hình Chatbot: Phát triển một mô hình chatbot dựa trên nền tảng Transformers, sử dụng một tập dữ liệu dành riêng cho Trường Đại học Công nghệ Đông Á.

Tra cứu thông tin: Chatbot sẽ có khả năng tra cứu thông tin liên quan đến Trường Đại học Công nghệ Đông Á, bao gồm quy chế, quy định, khóa học, chương trình đào tạo, học phí và nhiều thông tin khác.

Hỗ trợ hỏi đáp: Chatbot sẽ có khả năng hiểu và phản hồi tự nhiên đối với các câu hỏi liên quan đến Trường Đại học Công nghệ Đông Á, bất kể là câu hỏi cụ thể về trường học, thủ tục nhập học,...

Tích hợp và triển khai: Chatbot có thể được tích hợp vào trang web của Trường Đại học Công nghệ Đông Á hoặc các nền tảng khác để phục vụ cộng đồng của trường.

CHƯƠNG 1 - TỔNG QUAN

Chương này sẽ khảo sát, phân tích nhu cầu tra cứu thông tin về Trường Đại học Công nghệ Đông Á, từ việc tìm hiểu thông tin cơ bản đến các thông tin tuyển sinh, ngành học, chương trình học, tuyển dụng, nghiên cứu, và kết nối cộng đồng sinh viên và cựu sinh viên, đồng thời đánh giá hiệu quả của các giải pháp đang được áp dụng hiện nay.

1.1. NHU CẦU TRA CỨU THÔNG TIN THÔNG VỀ TRƯỜNG ĐẠI HỌC CÔNG NGHỆ ĐÔNG Á

Trường Đại học Công nghệ Đông Á được Thủ tướng chính phủ cho phép thành lập ngày 09/12/2008 theo Quyết định số 1777/QĐ-TTg [1]. Trường Đại học Công nghệ Đông Á là trường đại học đa ngành nằm trong hệ thống giáo dục quốc dân. Trường đào tạo các trình độ: Cao đẳng, Đại học và Sau đại học với nhiều hình thức: Chính quy, liên thông, vừa làm vừa học [1]. Với bề dày hơn 15 năm thành lập và hoạt động, Trường đại học Công nghệ Đông Á đã và đang là một trong những trường Đại học thu hút được lượng lớn sinh viên, nghiên cứu sinh theo học. Nhu cầu tìm hiểu thông tin, hợp tác, kết nối... cũng tăng lên đáng kể; việc tra cứu thông tin đã chuyển dịch phù hợp với xu thế của sự phát triển của công nghệ thông tin. Việc ứng dụng khoa học công nghệ, đặc biệt là công nghệ trí tuệ nhân tạo (Artificial Intelligence - AI) trở thành xu thế tất yếu nhằm tăng hiệu suất và giảm sự phụ thuộc vào con người đồng thời nâng tầm của chính đơn vị ứng dụng nó.

Thực trạng nhu cầu tra cứu thông tin về trường Đại học Công nghệ Đông Á được thể hiện qua các nội dung sau:

1.1.1. Học sinh, phụ huynh tìm hiểu thông tin về trường

Như chúng ta thấy trước mỗi kỳ thi tuyển sinh đại học, mỗi học sinh và phụ huynh của các em luôn phải chọn lựa ngành, nghề và trường cho các em

theo học. Để quyết định lựa chọn một ngôi trường, ngành, nghề phù hợp với mình, mỗi học sinh và phụ huynh đều phải tìm hiểu rất kỹ về ngôi trường và các thông tin liên quan. Mỗi năm có tới cả triệu thí sinh thi tốt nghiệp Trung học phổ thông và tuyển sinh Đại học. Mỗi học sinh hay phụ huynh mong muốn tìm hiểu như thông tin cụ thể như: Loại hình, hình thức và cấp đào tạo, chương trình học, bằng cấp, chứng chỉ, quy định, hồ sơ thi tuyển, hình thức tuyển sinh, cơ sở vật chất, trang thiết bị, đội ngũ Giảng viên, vị trí địa lý, học phí, hỗ trợ tài chính, học bổng, ưu đãi, uy tín, danh tiếng, áp dụng công nghệ trong đào tạo, giảng dạy, đầu ra sinh viên...

1.1.2. Tuyển dụng nhân lực

Đại học công nghệ Đông Á là cơ sở giáo dục đào tạo các hệ Đại học, Thạc sĩ với nhiều ngành nghề đang là xu thế của xã hội. Là đơn vị cung ứng nguồn nhân lực chất lượng cao và toàn diện, có phẩm chất đạo đức và trình độ chuyên môn giỏi [1]. Do đó, Đại học Công nghệ Đông Á là đơn vị tin cậy cho tuyển dụng nhân lực của các doanh nghiệp trên địa bàn và cả nước. Các doanh nghiệp khi muốn tuyển dụng nguồn nhân lực được Nhà trường đào tạo cũng sẽ tìm hiểu các thông tin liên quan về trường.

1.1.3. Thông tin tuyển dụng, cơ hội nghiên cứu

Hàng năm Nhà trường tuyển dụng những vị trí giảng viên, nhân viên cho các khoa và phòng ban. Việc cung cấp thông tin tuyển dụng trên các kênh thông tin truyền thông là không thể thiếu.

Giảng viên và sinh viên của trường đều là các nhà khoa học thực hiện nghiên cứu khoa học, với những đề tài cấp bộ môn, khoa và Trường; thông tin về nghiên cứu khoa học của trường cũng được truyền tải trên các kênh truyền thông.

1.1.4. Kết nối cộng đồng sinh viên, cựu sinh viên

Với bề dày đào tạo hơn 15 năm, Nhà trường đã có rất nhiều lớp sinh viên ra trường. Nhu cầu tìm hiểu thông tin về trường, kết nối cựu sinh viên là rất lớn. Mỗi sinh viên khi ra trường có thể đến mọi miền của Tổ quốc để làm việc, thậm trí là cả nước ngoài, họ có nhu cầu tìm kiếm thông tin, theo dõi quá trình phát triển của Nhà trường.

Đang học tại trường là các lớp sinh viên được sinh hoạt trong các nhóm, câu lạc bộ. Việc truy cập, chia sẻ thông tin về trường được thực hiện thường xuyên.

1.2. THỰC TRẠNG, CÁC GIẢI PHÁP ĐANG ĐƯỢC ÁP DỤNG TRONG TRA CỨU THÔNG TIN VỀ TRƯỜNG ĐẠI HỌC CÔNG NGHỆ ĐÔNG Á

1.2.1. Trang thông tin điện tử

Nhà trường đã ứng dụng công nghệ web trong xây dựng trang thông tin điện tử về Trường tại địa chỉ eaut.edu.vn. Là nơi cung cấp các thông tin từ cơ bản đến chi tiết về mọi mặt của Nhà trường. Trang web cung cấp các thông tin dưới dạng văn bản, hình ảnh, âm thanh và video. Việc tìm kiếm, hỏi đáp thông tin về trường đang được thực hiện thông qua các ứng dụng Facebook, Messenger và tawk.to. Các ứng dụng này đều phải tạo, quản lý tài khoản và trực tiếp con người sử dụng để trả lời các câu hỏi của người dùng và chưa sử dụng công nghệ tiên tiến của Chatbot.

1.2.2. Các sự kiện truyền thông

Để lan tỏa thông tin; Nhà trường đã sử dụng các sự kiện truyền thông như:

- Chào đón tân sinh viên được thực hiện mỗi năm;
- Lễ công nhận, trao bằng được thực hiện mỗi năm;

- Hội thảo khoa học các cấp;
- Ngày hội tuyển sinh;
- Ngày hội tuyển dụng...

1.2.3. Mạng xã hội

Với xu thế và sự bùng phát của các mạng xã hội; để quảng bá hình ảnh Nhà trường và truyền tải được nhiều thông tin hơn tới nhiều người hơn. Nhà trường đã sử dụng các mạng Xã hội như Zalo, Facebook để kết nối, chia sẻ thông tin.

1.2.4. Tư vấn học tập, tư vấn tuyển sinh

Là kênh truyền thông giúp truyền tải, cung cấp thông tin tới học sinh, sinh viên và người nhà học sinh. Nhà trường có đội ngũ tư vấn tuyển sinh chuyên nghiệp, chủ động trong công tác tư vấn. Mỗi khoa đều có các trợ lý học tập giúp sinh viên hiểu hơn về các quy định, quy chế và cách thực hiện các thủ tục trong Nhà trường. Tư vấn trực tiếp hoặc thông qua các mạng xã hội như Zalo, Facebook, Email...

1.3. ĐÁNH GIÁ HIỆU QUẢ CỦA CÁC GIẢI PHÁP ĐANG ĐƯỢC ỨNG DỤNG

Những giải pháp đang thực hiện đang thể hiện các ưu điểm như:

- Trang thông tin điện tử mang lại sự tiện lợi trong việc truy cập thông tin mọi lúc, mọi nơi với một thiết bị kết nối internet;
- Cung cấp một nguồn thông tin đa dạng về chương trình học, sự kiện và thông báo quan trọng;
- Sự kiện truyền thông tạo cơ hội cho tương tác trực tiếp giữa cộng đồng và trường Đại Học Công Nghệ Đông Á;
- Mạng xã hội tạo điều kiện cho tương tác liên tục và phản hồi từ cộng đồng;

- Tư vấn học tập và tuyển sinh cung cấp hỗ trợ cá nhân hóa cho sinh viên với thông tin độc đáo về khóa học và chương trình học.

Cùng với đó là những bất cập cần được giải quyết và khắc phục:

- Người dùng có thể gặp khó khăn khi tìm kiếm thông tin chi tiết trong các trang có nhiều nội dung;

- Sự kiện có thể giới hạn đối tượng tham gia và không tiện lợi cho những người không thể tham gia trực tiếp;

- Thông tin trên mạng xã hội có thể bị lan truyền nhanh chóng, nhưng cũng dễ bị hiểu lầm hoặc biến đổi;

- Có thể hạn chế về khả năng tương tác và truyền đạt thông tin tự nhiên;

- Cần sử dụng nhiều nhân lực trong các phương pháp truyền thống.

Việc tích hợp Chatbot vào hệ thống truyền thông có thể giúp tối ưu hóa các lợi ích và giảm thiểu các hạn chế. Chatbot có thể cung cấp thông tin linh hoạt, hỗ trợ tương tác đồng thời tăng cường trải nghiệm người dùng. Điều này giúp cả cộng đồng thuận tiện truy cập thông tin và tương tác với trường một cách hiệu quả và hấp dẫn.

1.4. CHATBOT VÀ ỨNG DỤNG CỦA CHATBOT [9]

1.4.1. Khái niệm Chatbot

Chatbot, viết tắt của "chat robot", là một phần mềm ứng dụng trí tuệ nhân tạo (AI) được thiết kế để mô phỏng và xử lý các cuộc trò chuyện của con người thông qua ngôn ngữ tự nhiên. Chatbot có khả năng tương tác với người dùng thông qua văn bản hoặc giọng nói, giúp tự động hóa các nhiệm vụ giao tiếp và cung cấp thông tin một cách hiệu quả. Những tiến bộ trong xử lý ngôn ngữ tự nhiên (NLP) và học sâu (deep learning) đã làm tăng cường khả năng của chatbot trong việc hiểu và phản hồi các truy vấn của người dùng một cách chính xác và tự nhiên.

1.4.2. Các loại Chatbot

Chatbot có thể được phân loại thành hai nhóm chính: chatbot dựa trên quy tắc (rule-based) và chatbot dựa trên AI.

Chatbot dựa trên quy tắc: Những chatbot này hoạt động dựa trên các quy tắc và kịch bản được lập trình sẵn. Chúng phản hồi theo các mẫu câu và từ khóa đã được xác định trước. Ưu điểm của loại chatbot này là dễ triển khai và kiểm soát, nhưng nhược điểm là hạn chế trong việc xử lý các truy vấn phức tạp và linh hoạt.

Chatbot dựa trên AI: Những chatbot này sử dụng công nghệ AI và học máy (machine learning) để học hỏi từ dữ liệu và cải thiện khả năng hiểu và phản hồi. Chúng có thể phân tích ngữ cảnh, học từ các tương tác trước đó và tự động điều chỉnh phản hồi. Nhược điểm của loại này là cần dữ liệu lớn và tài nguyên tính toán mạnh để huấn luyện và vận hành.

1.4.3. Ứng dụng của Chatbot

Chatbot đã được ứng dụng rộng rãi trong nhiều lĩnh vực khác nhau, mang lại nhiều lợi ích đáng kể.

Dịch vụ khách hàng: Chatbot có thể hoạt động 24/7 để hỗ trợ khách hàng, trả lời các câu hỏi thường gặp, giải quyết các vấn đề cơ bản và hướng dẫn khách hàng trong quá trình sử dụng sản phẩm hoặc dịch vụ. Điều này giúp giảm tải công việc cho nhân viên và cải thiện trải nghiệm khách hàng.

Thương mại điện tử: Trong ngành thương mại điện tử, chatbot có thể tư vấn sản phẩm, hỗ trợ quy trình đặt hàng, cung cấp thông tin về tình trạng đơn hàng và giải quyết các khiếu nại của khách hàng. Chatbot cũng có thể phân tích dữ liệu khách hàng để đề xuất sản phẩm phù hợp.

Giáo dục: Trong lĩnh vực giáo dục, chatbot có thể hỗ trợ học tập, giải đáp thắc mắc về bài học, cung cấp tài liệu học tập và nhắc nhở học sinh về lịch

học. Đặc biệt, chatbot có thể hỗ trợ trong việc tư vấn tuyển sinh, cung cấp thông tin về các khóa học và chương trình đào tạo.

Y tế: Trong y tế, chatbot có thể tư vấn sức khỏe, đặt lịch hẹn khám bệnh, cung cấp thông tin về triệu chứng bệnh và thuốc, và nhắc nhở bệnh nhân uống thuốc đúng giờ. Chatbot giúp giảm bớt gánh nặng cho các nhân viên y tế và cải thiện chất lượng chăm sóc sức khỏe.

Ngân hàng và tài chính: Chatbot có thể hỗ trợ khách hàng thực hiện các giao dịch ngân hàng, kiểm tra số dư tài khoản, tư vấn tài chính, và giải đáp các thắc mắc liên quan đến dịch vụ ngân hàng. Điều này giúp tăng cường hiệu quả dịch vụ và cải thiện trải nghiệm khách hàng.

1.4.4. Lợi ích của Chatbot

Chatbot mang lại nhiều lợi ích cho các tổ chức và doanh nghiệp, bao gồm:

Tăng cường hiệu quả: Chatbot có thể xử lý một lượng lớn yêu cầu cùng lúc mà không gặp phải sự mệt mỏi, giúp tăng cường hiệu quả làm việc và giảm thiểu thời gian chờ đợi của khách hàng.

Tiết kiệm chi phí: Sử dụng chatbot giúp giảm chi phí nhân công cho các công việc lặp đi lặp lại và tăng cường tự động hóa các quy trình kinh doanh.

Nâng cao trải nghiệm khách hàng: Chatbot cung cấp dịch vụ liên tục 24/7, giúp giải đáp kịp thời các thắc mắc của khách hàng và cải thiện sự hài lòng của họ.

Thu thập và phân tích dữ liệu: Chatbot có khả năng thu thập và phân tích dữ liệu từ các tương tác với khách hàng, giúp doanh nghiệp hiểu rõ hơn về nhu cầu và hành vi của khách hàng để đưa ra các chiến lược kinh doanh phù hợp.

1.4.5. Thách thức trong việc triển khai Chatbot

Mặc dù có nhiều lợi ích, việc triển khai chatbot cũng đối mặt với một số thách thức:

Hiểu ngữ cảnh: Việc hiểu và xử lý ngữ cảnh trong các cuộc trò chuyện phức tạp là một thách thức lớn đối với chatbot.

Bảo mật và quyền riêng tư: Việc bảo vệ thông tin cá nhân và đảm bảo quyền riêng tư của người dùng là một vấn đề quan trọng khi triển khai chatbot.

Chất lượng dữ liệu: Chatbot dựa trên AI cần dữ liệu lớn và chất lượng cao để huấn luyện. Dữ liệu không đầy đủ hoặc không chính xác có thể ảnh hưởng đến hiệu quả của chatbot.

Tương tác tự nhiên: Để tạo ra trải nghiệm tương tác tự nhiên, chatbot cần được thiết kế sao cho phản hồi một cách linh hoạt và phù hợp với ngữ cảnh.

CHƯƠNG 2 - CƠ SỞ LÝ THUYẾT

Chương này sẽ đi sâu vào khám phá về Transformers, trình bày về quá trình huấn luyện và đặc trưng của các mô hình ngôn ngữ lớn (Large Language Model - LLMs).

2.1. MẠNG NƠ-RON KẾT NỐI ĐẦY ĐỦ


Mạng nơ-ron nhân tạo là một nhánh của học máy (Machine learning) dựa trên sự hiểu biết về hoạt động của não người. Một ANN được tạo bởi nhiều nơ-ron cùng với nhiều kết nối, được tổ chức thành các lớp. Các nơ-ron của một lớp sẽ kết nối với các nơ-ron của một hoặc một số lớp tiếp theo [4].

ANN đầu tiên được giới thiệu vào giữa thế kỷ 20 gồm 2 lớp mang tên Perceptron để thực hiện các phép toán đơn giản, sau đó được mở rộng với thuật toán lan truyền ngược (Back Propagation) để tăng hiệu quả của quá trình huấn luyện đối với mạng nhiều lớp. Các ANN chỉ thực sự bùng nổ vào năm 2011 với sự ra đời của Bộ xử lý đồ họa (Graphic Processing Unit - GPU), cùng với một lượng lớn dữ liệu sẵn có phục vụ quá trình huấn luyện.

Học sâu là khái niệm đề chỉ các ANN có nhiều lớp. Ban đầu, khái niệm Deep learning chỉ các mạng ANN có từ 3 đến 5 lớp, nhưng hiện nay các mạng ANN có thể nhiều hơn 200 lớp.

Mặc dù còn nhiều quan điểm khác nhau về quá trình học của não người, nhưng đều thống nhất chung rằng: não bộ được tổ chức bởi các lớp khác nhau. Hệ thống thị giác được kết nối với vùng vỏ não phụ trách xử lý trực quan, đây là phần dưới phía sau trong não bộ của chúng ta.

Mạng nơ-ron là sự kết hợp của những lớp Perceptron hay còn gọi là Perceptron đa lớp. Và mỗi một mạng nơ-ron thường bao gồm 3 kiểu lớp: Lớp đầu vào (Input Layer), các lớp ẩn (Hidden Layer) và lớp đầu ra (Output Layer).



Hình 2.1. Mô hình mạng nơ-ron

Tại mỗi lớp, số lượng nút mạng có thể khác nhau tùy vào bài toán hoặc cách giải quyết bài toán.

Trường hợp một nơ-ron bất kỳ ở lớp thứ i luôn liên kết với tất cả các nơ-ron ở lớp thứ $i+1$ thì được gọi là mạng nơ-ron kết nối đầy đủ. Và đây cũng là mạng nơ-ron cơ bản nhất, nhưng nó vẫn còn cho thấy hiệu quả trong nhiều bài toán. Đặc biệt là sự thành công của kiến trúc Transformers càng cho thấy tầm quan trọng của mạng kết nối đầy đủ. Bên cạnh ưu điểm nổi bật của mạng kết nối đầy đủ là tính toán nhanh, mạng này có hạn chế là số lượng tham số khá lớn nên có nguy cơ dẫn đến hiện tượng overfitting trong quá trình huấn luyện.

Tuy nhiên hiện tượng này có thể khắc phục được bằng một số kỹ thuật xử lý phổ biến như Dropout, hay BatchNormalization,...


Lớp đầu vào: Là lớp nhận các dữ liệu đầu vào và chuyển tiếp chúng đến các lớp tiếp theo. Đầu vào một nơ-ron là một đại lượng vô hướng; số đầu vào của nơ-ron của lớp này bằng với số chiều của dữ liệu.

Các lớp ẩn: Bao gồm các nơ-ron nhân tạo, được kết nối với các lớp trước và sau, số lượng lớp ẩn tỷ lệ thuận với độ phức tạp của bài toán. Về cơ bản, bài toán càng phức tạp thì số lớp ẩn càng nhiều, điều này sẽ giúp cho mạng học được những đặc trưng phức tạp từ dữ liệu. Với công nghệ ngày nay, chúng ta có thể dễ dàng huấn luyện một mạng có đến hàng trăm lớp ẩn.

Lớp đầu ra: Là lớp nhận các giá trị từ lớp ẩn cuối cùng và trả về kết quả đầu ra của mạng. Các nơ-ron trong lớp này thường có được kích hoạt khác với các lớp ẩn để phù hợp với loại bài toán cần giải quyết.

2.1.1. Khái niệm về mạng nơ-ron kết nối đầy đủ

Mạng nơ-ron kết nối đầy đủ (fully connected neural network), còn được gọi là mạng nơ-ron truyền thẳng (feedforward neural network), là một loại kiến trúc mạng nơ-ron cơ bản trong học sâu. Trong mạng nơ-ron này, mỗi nơ-ron trong một lớp được kết nối với tất cả các nơ-ron trong lớp liền trước và lớp liền sau nó [6].




Hình 2.2. Mạng nơ-ron kết nối đầy đủ

Mạng nơ-ron kết nối đầy đủ bao gồm ít nhất một lớp đầu vào, một hoặc nhiều lớp ẩn, và một lớp đầu ra. Trong mỗi lớp, mỗi nơ-ron được kết nối với tất cả các nơ-ron trong lớp liền trước và lớp liền sau nó bằng các trọng số và độ lệch. Mỗi nơ-ron trong các lớp ẩn và lớp đầu ra thường được áp dụng một hàm kích hoạt phi tuyến tính, như hàm sigmoid, tanh, hoặc ReLU, để tạo ra đầu ra phi tuyến. Tính toán đầu ra của mạng bằng cách truyền dữ liệu từ lớp đầu vào qua các lớp ẩn cho đến lớp đầu ra. Quá trình này không có chu kỳ phản hồi, nghĩa là không có kết nối ngược từ lớp đầu ra đến các lớp ẩn.

2.1.2. Hiện tượng overfitting, underfitting và cách khắc phục

Overfitting: Khi mô hình có độ chính xác cao với bộ dữ liệu huấn luyện, nhưng độ chính xác thấp với bộ dữ liệu mới (hay dữ liệu tổng thể) [6].



Hình 2.3. Hàm mục tiêu và overfitting

Underfitting là hiện tượng khi mô hình xây dựng chưa có độ chính xác cao trong tập dữ liệu huấn luyện cũng như tổng quát hóa với tổng thể dữ liệu. Khi hiện tượng Underfitting xảy ra, mô hình đó sẽ không phải là tốt với bất kì bộ dữ liệu nào trong từng bài toán cụ thể.

2.2. MẠNG HỒI QUY VÀ BÀI TOÁN S2S


2.2.1. Kiến trúc mạng hồi quy cho bài toán S2S

Một vấn đề đặt ra trong xử lý ngôn ngữ tự nhiên là xác định từ, cụm từ tiếp theo trong ngữ cảnh của câu hỏi hay của từ trước đó tức là việc suy luận dựa trên những từ lân cận vị trí hiện tại để đưa ra từ tiếp theo một cách chính xác, phù hợp với ngữ cảnh. Một trong những điểm nổi bật của mạng nơ-ron hồi quy là các mạng con có thể sử dụng dữ liệu trước đó để xử lý cho công việc hiện tại [8].

Mạng bộ nhớ ngắn hạn - dài hạn (Long Short-Term Memory - LSTM) là một loại nơ-ron hồi quy đặc biệt, có khả năng học các phụ thuộc dài hạn. Chúng được giới thiệu bởi Hochreiter & Schmidhuber (1997) và được nhiều người cải


tiên, áp dụng rộng rãi trong các giải pháp trong đó bài toán S2S là một điển hình [8].

LSTM thường có các lớp tương tác với nhau theo phương thức được quy định từ trước của chúng.



Hình 2.4. Ví dụ mạng nơ-ron hồi quy LSTM

Trong đó các ký hiệu được giải thích:



Hình 2.5. Các thành phần trong mạng nơ-ron hồi quy LSTM

Biểu tượng vòng tròn màu hồng biểu thị các phép cộng véc-tơ, hình chữ nhật màu vàng biểu thị cho các lớp mạng nơ-ron. Các mũi tên đơn màu đen biểu thị cho sự ghép nối, các mũi tên phân nhánh biểu thị cho nội dung đang được sao chép.

2.2.2. Ưu điểm và hạn chế của mạng hồi quy đối với bài toán S2S

Ưu điểm:

- Khả năng xử lý dữ liệu tuần tự: Mạng hồi quy rất phù hợp với dữ liệu tuần tự như văn bản, vì chúng có khả năng ghi nhớ thông tin từ các bước trước và sử dụng thông tin đó để dự đoán bước tiếp theo;

- Khả năng xử lý các chuỗi có độ dài khác nhau: Trong bài toán dịch ngôn ngữ, đầu vào và đầu ra thường có độ dài khác nhau. Mạng hồi quy có thể xử lý điều này một cách tự nhiên.

Hạn chế:

- Vấn đề về bộ nhớ dài hạn: Mặc dù mạng hồi quy như LSTM và GRU đã giải quyết được vấn đề độ dốc trở nên rất nhỏ hoặc biến mất trong quá trình huấn luyện, chúng vẫn gặp khó khăn trong việc ghi nhớ thông tin qua các chuỗi dài;

- Tốc độ huấn luyện: Do tính tuần tự của dữ liệu, việc huấn luyện mạng hồi quy thường mất nhiều thời gian hơn so với các loại mạng nơ-ron khác.

2.4. TRANSFORMERS


2.4.1. Kiến trúc Transformers

Transformers là mô hình bao gồm 2 thành phần chính: mã hóa (Encoder) và giải mã (Decoder).

Encoder là một ngăn xếp gồm 6 lớp riêng biệt xếp chồng lên nhau, số lớp ở đây có thể tùy chỉnh phụ thuộc vào mục đích từng bài toán. Mỗi lớp bao gồm 2 lớp con, đầu tiên là lớp xử lý chú ý đa đầu (Multi-head Attention) và lớp con thứ hai đơn giản là một mạng nơ-ron truyền thẳng (Feed-forward). Kết nối phần dư (Residuals Connection) bao quanh hai lớp con này tiếp theo đó là bước chuẩn hóa lớp (Layer Normalization) giúp mô hình huấn luyện hiệu quả hơn và tránh mất mát thông tin [7].

Decoder cũng được cấu thành từ 6 lớp riêng biệt (cùng số lớp với encoder). Mỗi lớp bao gồm 2 lớp con giống với encoder và thêm một lớp Multi-head attention nằm ở giữa giúp Decoder tạo được mối tương quan với câu đầu vào. Giống với Encoder kỹ thuật Residual Connection và Layer Normalization cũng được áp dụng trên các lớp con. Có một sự thay đổi ở lớp con Multi-head Attention đầu tiên, thay vì truyền tất cả các từ trong câu vào Decoder, thực hiện

che đi các từ chưa được mô hình dịch đến gọi là cơ chế Masked Multi-head Attention.



Hình 2.6. Sơ đồ mô hình Transformers


2.4.2. Mã hóa vị trí của từ

Word embedding giúp biểu diễn ngữ nghĩa của một từ, tuy nhiên cùng một từ ở vị trí khác nhau của câu lại mang ý nghĩa khác nhau. Do đó Transformers có thêm một phần Positional Encoding để đưa thêm thông tin về vị trí của một từ.

$$PE_{(pos, 2i)} = \sin(pos/1000^{2i/d_{model}}) \quad (2.1)$$

$$PE_{(pos, 2i+1)} = \cos(pos/10000^{2i/d_{model}}) \quad (2.2)$$

Trong đó pos là vị trí của từ trong câu, PE là giá trị phần tử thứ i trong embeddings có độ dài d_{model} . Sau đó cộng véc-tơ PE và véc-tơ Embedding.



Hình 2.7. Mã hóa vị trí từ nhúng

2.4.3. Self-Attention và Cross -Attention

Sử dụng mạng LSTM gặp phải một số khó khăn sau:

Thời gian huấn luyện dài và khó khăn: Do gradient path trong LSTM rất dài, đặc biệt khi xử lý các chuỗi dài, điều này làm tăng thời gian và độ phức tạp của quá trình huấn luyện. Mỗi chuỗi dữ liệu, dù có độ dài ngắn khác nhau đều tương đương với việc huấn luyện một mạng có số lớp tương ứng, gây ra khó khăn trong quá trình tối ưu hóa.


Transfer learning không hiệu quả: LSTM thường không thích ứng tốt với việc chuyển giao kiến thức từ một nhiệm vụ huấn luyện sang một nhiệm vụ mới. Điều này có nghĩa là khi áp dụng LSTM vào một bài toán mới, thường

cần phải huấn luyện lại mô hình với dữ liệu mới, tốn kém thời gian và tài nguyên.

Hạn chế của mô hình seq2seq: Trong mô hình seq2seq với LSTM, việc encoder "nén" toàn bộ chuỗi đầu vào thành một vector biểu diễn duy nhất có thể dẫn đến việc mất mát thông tin quan trọng, đặc biệt là khi chuỗi đầu vào có độ dài lớn. Decoder chỉ có thể nhìn vào một vector đầu vào duy nhất, điều này làm giảm khả năng xử lý các phần khác nhau của chuỗi đầu vào tại từng bước, dẫn đến sự giới hạn trong việc trích xuất thông tin cần thiết. Cơ chế chú ý (Attention mechanism) ra đời để giải quyết vấn đề này bằng cách tập trung vào các phần quan trọng của chuỗi đầu vào tại mỗi bước trong quá trình giải mã.

Self-Attention:

Cơ chế tự chú ý (Self-Attention) là cơ chế giúp Transformers "hiểu" được sự liên quan giữa các từ trong một câu. Ví dụ như từ "kicked" trong câu "I kicked the ball" (tôi đã đá quả bóng) liên quan như thế nào đến các từ khác? Liên quan mật thiết đến từ "I" (chủ ngữ), "kicked" là chính nó lên sẽ luôn "liên quan mạnh" và "ball" (vị ngữ). Ngoài ra từ "the" là giới từ nên sự liên kết với từ "kicked" gần như không có [7].



Hình 2.8. Cơ chế Self-Attention

Đầu vào của các mô-đun Multi-head Attention có ba mũi tên là ba véc-tơ Querys (Q), Keys (K) và Values (V). Từ ba véc-tơ này, tính véc-tơ attention Z cho một từ theo công thức sau:

$$Z = \text{soft max} \left(\frac{Q \cdot K^T}{\sqrt{\text{Dimension of vector Q K or V}}} \right) \cdot V \quad (2.3)$$

Thực hiện tính như sau:

Bước 1: Tính ba véc-tơ Q, K, V, input embedding được nhân với ba ma trận trọng số tương ứng WQ, WK, WV.

Bước 2: véc-tơ K đóng vai trò như một biểu diễn cho từ trong câu, được sử dụng như các "khóa". Vector Q, đại diện cho từ hiện tại hoặc từ đang được xem xét, sẽ truy vấn đến các vector K của các từ khác trong câu bằng cách thực hiện phép nhân chập với chúng. Nhân chập để tính toán độ liên quan giữa các từ với nhau (2 từ liên quan đến nhau sẽ có "Score" lớn). Bước "Scale" chia "Score" cho căn bậc hai của số chiều của Q/K/V (trong hình chia 8 vì Q/K/V là 64-D véc-tơ) giúp giá trị "Score" không phụ thuộc vào độ dài của véc-tơ Q/K/V.

Bước 3: Sử dụng hàm softmax để chuẩn hóa các giá trị kết quả về đoạn từ 0 đến 1. Kết quả của quá trình này thể hiện mức độ tương đồng giữa Q và K. Nếu giá trị là 1 tức là tương đồng hoàn toàn và 0 biểu thị sự không tương đồng.

Bước 4: Nhân phân bố xác suất đó với véc-tơ V để loại bỏ những từ không cần thiết (xác suất nhỏ) và giữ lại những từ quan trọng (xác suất lớn).

Bước 5: Thực hiện cộng các vector V để tạo ra véc-tơ chú ý Z cho một từ cụ thể. Quá trình này được lặp lại cho tất cả các từ trong câu để tạo ra ma trận chú ý cho câu đó.

Cross Attention:

Cơ chế chú ý chéo (Cross-Attention) hoặc lớp chú ý chéo, cho phép các mô hình xử lý ngôn ngữ tự nhiên (Natural Language Processing - NLP) nắm bắt các mối quan hệ phức tạp và sự phụ thuộc giữa các chuỗi đầu vào khác nhau. Nó vượt xa cơ chế tự chú ý, tập trung vào sự hiểu biết trong một chuỗi duy nhất và cho phép mô hình tiếp thu thông tin từ nhiều nguồn một cách hiệu quả.

Chú ý chéo hoạt động bằng cách tính toán trọng số attention phản ánh mức độ liên quan của từng phần tử trong chuỗi này với các phần tử trong chuỗi khác. Bằng cách tận dụng các truy vấn, khóa và giá trị, cơ chế này sẽ tính toán trọng số chú ý dựa trên sự tương đồng hoặc tương quan giữa các chuỗi. Ngược lại, các trọng số này được sử dụng để tạo ra các véc-tơ ngữ cảnh nhằm nắm bắt thông tin quan trọng từ chuỗi khác. Khả năng mạnh mẽ này cho phép các mô hình trích xuất những hiểu biết sâu sắc về sắc thái và đưa ra quyết định sáng suốt trong các nhiệm vụ NLP khác nhau.

2.4.4. Một số LLM nổi tiếng sử dụng kiến trúc Transformers


Bidirectional Encoder Representations from Transformers (BERT):

BERT được hiểu là một mô hình huấn luyện trước (Pre-train Model), các véc-tơ đại diện theo ngữ cảnh 2 chiều của từ, được sử dụng để transfer sang các bài toán khác trong lĩnh vực xử lý ngôn ngữ tự nhiên. BERT được áp dụng thành công trong việc xác định biểu diễn số hóa của từ trong không gian số dựa trên ngữ cảnh mà từ đó xuất hiện.

BERT là mô hình được xây dựng và huấn luyện bởi Google trên kho văn bản lớn gồm Toronto Book Corpus và Wikipedia [9]. BERT được thiết kế để huấn luyện trước các biểu diễn hai chiều từ văn bản không được gắn nhãn bằng cách điều hòa chung cả ngữ cảnh bên trái và bên phải trong tất cả các lớp. Do đó, mô hình BERT được huấn luyện trước có thể được tinh chỉnh chỉ với một lớp đầu ra bổ sung để tạo ra các mô hình hiện đại cho nhiều nhiệm vụ, chẳng hạn như trả lời câu hỏi và suy luận ngôn ngữ mà không cần phải thực hiện tác vụ quan trọng nào nhằm sửa đổi kiến trúc cụ thể.

BERT được thiết kế để tạo ra các biểu diễn ngôn ngữ hai chiều từ văn bản chưa được gắn nhãn thông qua việc đồng nhất thông tin từ cả hai phía ngữ cảnh, từ trái sang phải và ngược lại tại tất cả các lớp. Vì vậy BERT có khả năng học được các biểu diễn tự nhiên và phong phú của từ trong ngữ cảnh của chúng.

Mô hình BERT đã được huấn luyện trước có thể dễ dàng tinh chỉnh cho các nhiệm vụ cụ thể chỉ bằng cách thêm một lớp đầu ra mới, mà không cần phải điều chỉnh toàn bộ kiến trúc. Điều này mở ra khả năng xây dựng các mô hình ngôn ngữ lớn và hiện đại thực hiện các nhiệm vụ như trả lời câu hỏi và suy luận ngôn ngữ mà không yêu cầu quá nhiều công sức đối với việc sửa đổi kiến trúc.




Hình 2.9. Mô hình BERT

Generative Pre-training Transformers (GPT):

GPT là một dòng mô hình ngôn ngữ tự nhiên dựa trên kiến trúc Transformers, được phát triển bởi OpenAI. Mục tiêu chính của GPT là một mô hình có khả năng tạo ra văn bản tự nhiên và hiểu ngữ cảnh ngôn ngữ.

GPT sử dụng kiến trúc Transformers, một mô hình mạng nơ-ron sâu không đệ quy, nhưng có khả năng hiểu và mô hình hóa các mối quan hệ phức tạp trong ngôn ngữ tự nhiên. Kiến trúc này cho phép mô hình học được các biểu diễn phân phối cho từng từ trong câu một cách hiệu quả.

GPT được huấn luyện trước trên một lượng lớn dữ liệu văn bản không được gắn nhãn từ Internet hoặc các nguồn dữ liệu khác. Sau đó, mô hình được tinh chỉnh trên các tác vụ cụ thể như phân loại văn bản, dịch máy hoặc sinh văn bản. Có khả năng sinh ra văn bản tự nhiên và đa dạng. Điều này có nghĩa là mô hình có thể tạo ra các đoạn văn bản mới dựa trên ngữ cảnh đã được cung cấp và mỗi lần sinh ra có thể cho ra kết quả khác nhau.



Hình 2.10. Mô hình GPT


Một số phiên bản của GPT:

- GPT2 (Medium, Large): phiên bản này có 1,5 tỷ tham số
- GPT3: với 175 tỷ tham số
- GPT4: với 4000 tỷ tham số.

Large Language Model Meta AI (LlaMA):


LlaMA là mô hình ngôn ngữ lớn về AI của Meta với 70 tỷ tham số, nó hoạt động dưới dạng OpenSource, hoàn toàn miễn phí cho phép các nhà nghiên cứu, tổ chức chính phủ, xã hội sử dụng miễn phí. LLaMA tập trung hỗ trợ cho

20 ngôn ngữ dùng bảng chữ cái Latinh, đáng tiếc là Tiếng Việt của chúng ta chưa nằm trong danh sách này.



Hình 2.11. Mô hình LLaMA

2.4.5. Quá trình huấn luyện và đặc trưng của LLMs



Hình 2.12. Quá trình huấn luyện mô hình ngôn ngữ

Các mô hình ngôn ngữ lớn ban đầu được huấn luyện thông qua học tự giám sát trên kho dữ liệu văn bản khổng lồ mà không cần nhãn. Sau giai đoạn huấn luyện tự giám sát, chúng ta có một mô hình ngôn ngữ đã được huấn luyện. Mô hình này đã học được các mẫu ngữ nghĩa và cú pháp từ dữ liệu huấn luyện với toàn bộ dữ liệu trên Wikipedia và 11.038 quyển sách.

Bảng 2.1. Cơ sở dữ liệu Pre-trained LLMs

Mô hình	Cơ sở dữ liệu training	Số lượng Tokens
GPT3	Common Crawl, Webtext2, Books, Wikipedia	499 B
LlaMa2	CommonCrawl, Github, Wikipedia, Books, ArXiv, StackExchange	2000 B

Để thực hiện những nhiệm vụ cụ thể, trên những tập dữ liệu mới, đặc thù của từng nhiệm vụ; mô hình sẽ được chuyển sang giai đoạn tinh chỉnh. Mô hình đã được huấn luyện sẽ được điều chỉnh để tối ưu hóa hiệu suất trên tác vụ cụ thể. Những tác vụ này có thể bao gồm “Trả lời câu hỏi”, “Phân loại văn bản” và “Truy xuất thông tin”. Mỗi tác vụ sẽ yêu cầu một cách tinh chỉnh cụ thể và

có thể yêu cầu dữ liệu tinh chỉnh riêng. Các mô hình khác nhau cũng thực hiện các tác vụ khác nhau:

Bảng 2.2. Các tác vụ thực hiện trong quá trình fine-tuning

Mô hình	Các tác vụ thực hiện
BERT	Phân tích cảm xúc
	Nhận diện các thực thể đã được đặt tên
	Hỏi đáp
	Phân loại văn bản
	Gán nhãn vai trò ngữ nghĩa
GPT	Hoàn thành văn bản
	Dịch máy
	Tóm tắt
	Trợ lý trò chuyện và AI hội thoại
	Trợ lý viết sáng tạo

CHƯƠNG 3 - XÂY DỰNG HỆ THỐNG CHATBOT SỬ DỤNG LLMs

Chương này tập trung vào việc xây dựng một hệ thống Chatbot cho trường Đại học Công nghệ Đông Á, sử dụng LLMs. Các phương pháp huấn luyện LLMs, bao gồm huấn luyện trước và tinh chỉnh, cũng như các kỹ thuật nâng cao hiệu suất, tối ưu hóa bộ nhớ và giảm độ phức tạp tính toán. Đề án này áp dụng VectorDB và kỹ thuật Retrieval-Augmented Generation (RAG) vào việc xây dựng hệ thống ChatBot. Quá trình xây dựng hệ thống Chatbot được trình bày từ bước thu thập và tiền xử lý dữ liệu, xây dựng kiến trúc hệ thống Chatbot và đưa ra một số kết quả thử nghiệm.

3.1. SỰ CẦN THIẾT LOCAL CHATGPT ĐỐI VỚI DOANH NGHIỆP

Áp dụng Local Chat Generative Pre-training Transformer (Local ChatGPT) có thể mang lại nhiều lợi ích cho doanh nghiệp, cụ thể như:

- Giúp cải thiện hiệu quả và tốc độ phản hồi trong việc xử lý yêu cầu của khách hàng, giảm bớt gánh nặng cho nhân viên hỗ trợ khách hàng và tăng cường khả năng tương tác tự động với khách hàng;
- Được tinh chỉnh để hiểu rõ hơn về ngữ cảnh cụ thể của doanh nghiệp, như lĩnh vực, sản phẩm và dịch vụ của doanh nghiệp, giúp Local ChatGPT cung cấp thông tin chính xác và phù hợp hơn cho khách hàng. Điều này đặc biệt quan trọng đối với các doanh nghiệp như các trường Đại học, nơi mà thông tin cụ thể và chính xác về các chương trình học, học phí và quy định có thể rất quan trọng đối với sinh viên tiềm năng;
- Dữ liệu tinh chỉnh được đặt ngay tại hạ tầng của doanh nghiệp mà không cần tải lên bất cứ một hệ thống trung gian nào. Điều này đảm bảo tính bảo mật dữ liệu nhạy cảm của doanh nghiệp;
- Giúp doanh nghiệp tiếp cận với công nghệ AI mới nhất, giúp họ duy trì lợi thế cạnh tranh trong thời đại số hóa ngày nay.

3.2. PHƯƠNG PHÁP HUẤN LUYỆN LLMS

3.2.1. Pre-trained

Huấn luyện trước mô hình (Pre-trained); với phương pháp này mô hình được huấn luyện trên một lượng lớn dữ liệu văn bản không được gán nhãn. Mục tiêu là học cách dự đoán từ tiếp theo trong một chuỗi dựa trên các từ đã biết. Quá trình này giúp mô hình học được ngữ cảnh và ngữ nghĩa của từ ngữ, cũng như cấu trúc ngữ pháp của ngôn ngữ.

3.2.2. Fine-Tuning

Sau khi mô hình đã được huấn luyện trước, nó có thể được tinh chỉnh (Fine-Tuning) trên một tập dữ liệu nhỏ hơn và cụ thể hơn. Tập dữ liệu này thường được gán nhãn và liên quan trực tiếp đến tác vụ mà mô hình sẽ thực hiện, như dịch ngôn ngữ, trả lời câu hỏi, tìm kiếm và tra cứu thông tin. Quá trình tinh chỉnh giúp mô hình điều chỉnh các tham số của nó để tối ưu hóa hiệu suất trên tác vụ cụ thể. Điều này có thể bao gồm việc học cách hiểu các câu hỏi cụ thể về doanh nghiệp hoặc cách tìm kiếm thông tin cụ thể trong cơ sở dữ liệu của doanh nghiệp.

3.2.3. Một số thách thức trong việc huấn luyện LLMs

Huấn luyện một mô hình ngôn ngữ lớn (LLMs) đặt ra nhiều thách thức, bao gồm:

- Yêu cầu về tài nguyên tính toán: Huấn luyện LLMs đòi hỏi một lượng lớn tài nguyên tính toán, bao gồm: CPU, GPU, và bộ nhớ. Điều này có thể tạo ra rào cản về mặt chi phí và khả năng tiếp cận cho các tổ chức nhỏ hoặc ở các quốc gia có hạn chế về tài nguyên tính toán;

- Dữ liệu huấn luyện: LLMs cần một lượng lớn dữ liệu văn bản để huấn luyện. Tuy nhiên, việc thu thập, làm sạch và xử lý dữ liệu này có thể là một

thách thức. Hơn nữa, việc đảm bảo rằng dữ liệu huấn luyện không chứa thông tin nhạy cảm hoặc thiên vị cũng là một vấn đề quan trọng;

- Thời gian huấn luyện: Việc huấn luyện một LLM có thể mất hàng tuần hoặc thậm chí hàng tháng, tùy thuộc vào kích thước của mô hình và tài nguyên tính toán có sẵn. Điều này có thể làm chậm tiến trình phát triển và triển khai mô hình;

- Kiểm soát đầu ra của mô hình: LLMs có thể tạo ra các đầu ra không mong muốn, bao gồm thông tin không chính xác, thiên vị hoặc gây sốc. Việc kiểm soát và giảm thiểu những vấn đề này là một thách thức lớn;

- Bảo mật và quyền riêng tư: LLMs có thể “học” từ dữ liệu huấn luyện và tiết lộ thông tin nhạy cảm. Việc bảo vệ dữ liệu và đảm bảo quyền riêng tư của người dùng là một vấn đề quan trọng khi huấn luyện và triển khai LLMs;

- Tất cả những điều này dẫn đến chi phí huấn luyện LLMs cho Chatbot của doanh nghiệp là quá lớn.

3.3. NÂNG CAO HIỆU SUẤT LLMS

Khi huấn luyện và sử dụng các mô hình ngôn ngữ lớn (LLMs) như BERT, GPT, LLaMA, Mistral..., một trong những thách thức lớn nhất là nhu cầu về tài nguyên phần cứng. Các mô hình này có hàng trăm triệu đến hàng tỷ tham số, đòi hỏi một lượng lớn bộ nhớ và sức mạnh tính toán để huấn luyện và sử dụng. Việc huấn luyện và sử dụng các mô hình này không chỉ đòi hỏi tài nguyên phần cứng mạnh mẽ, mà còn phát sinh những chi phí như vận hành, bảo trì, năng lượng, nhân sự có trình độ. Kéo theo đó là vấn đề về tài chính: việc mua sắm, duy trì và nâng cấp hệ thống phần cứng cần thiết sẽ rất tốn kém.

Hơn nữa với số lượng tham số ngày càng lớn cũng kéo theo các vấn đề liên quan đến: thời gian cần thiết để huấn luyện mô hình tăng lên, việc quản lý và lưu trữ các tham số trở nên phức tạp hơn. Những điều trên đặt ra thách thức

về việc mở rộng phần cứng đối với các doanh nghiệp và làm chậm tiến trình phát triển cũng như triển khai các ứng dụng.

Xem xét một ví dụ cụ thể về chi phí cho việc huấn luyện một mô hình ngôn ngữ lớn sau. Với LLaMa-65B có 65 tỷ tham số, việc huấn luyện sẽ sử dụng card A100 GPU. Nếu sử dụng 2048 card A100 GPU để huấn luyện 1.4T token thì sẽ mất 21 ngày. Giá thành cho việc thuê A100 là 3.5\$ (USD) cho mỗi giờ. Như vậy chi phí cho một lần huấn luyện sẽ là: $\$3.5/\text{hr} * 2048 * 24 * 21 = \3.6M .

Như vậy chúng ta thấy rằng việc các doanh nghiệp thực hiện training hay tinh chỉnh và sử dụng một mô hình ngôn ngữ lớn là bất khả thi. Để giải quyết vấn đề nêu trên; trong phần này sẽ trình bày một số kỹ thuật giảm chi phí phần cứng trong triển khai LLMs.

3.3.1. Tối ưu hóa bộ nhớ LLM bằng kỹ thuật lượng tử


Đối với các mô hình ngôn ngữ lớn hơn một tỷ tham số, việc quản lý RAM GPU hiệu quả là điều then chốt. Một tham số mô hình với độ chính xác tối đa thường được lưu trữ với 32 bit cần 4 byte dung lượng, nghĩa là yêu cầu 4GB RAM GPU chỉ để tải mô hình có 1 tỷ tham số. Quá trình huấn luyện thực tế thậm chí còn đòi hỏi nhiều bộ nhớ hơn để chứa các thành phần khác nhau bao gồm trạng thái tối ưu hóa và độ dốc, có khả năng cần tới 80GB RAM GPU cho một mô hình ở quy mô này.

Để giải quyết các hạn chế của RAM GPU trong biểu diễn các tham số của mô hình, lượng tử hóa được sử dụng, đây là một kỹ thuật làm giảm độ chính xác của các tham số mô hình, do đó giảm yêu cầu bộ nhớ. Ví dụ: việc thay đổi độ chính xác từ 32 bit thành 16 bit có thể giảm một nửa bộ nhớ cần thiết cho cả việc tải và huấn luyện mô hình.

Trong một số trường hợp, chúng ta có thể giảm độ chính xác của các tham số xuống còn 8 bit. Tuy nhiên, việc này có thể làm mất đi một lượng thông tin đáng kể, do đó cần cân nhắc kỹ lưỡng trước khi sử dụng.

Đối với những trường hợp cần giảm bộ nhớ và tăng tốc độ xử lý là mục tiêu hàng đầu thì sử dụng 4 bit để lưu trữ tham số là giải pháp tốt. Phương pháp này sẽ làm giảm đáng kể yêu cầu về bộ nhớ của GPU và tăng tốc cho việc huấn luyện mô hình. Đổi lại phương pháp này cũng làm mất đi khá nhiều thông tin lưu trữ trong tham số vì thế mức độ tối ưu của mô hình là không cao.

Ví dụ về bộ nhớ yêu cầu cho GPU biểu diễn các tham số cũng như tải và huấn luyện mô hình có 1 tỷ tham số.




Hình 3.1. Yêu cầu bộ nhớ cho tải và huấn luyện mô hình

Qua ví dụ trên chúng ta có thể thấy được sự khác biệt khá lớn về bộ nhớ yêu cầu trong hai kỹ thuật biểu diễn tham số dùng 16 bit và 32 bit.

3.3.2. Giảm độ phức tạp tính toán bằng kỹ thuật LoRA

Low-Rank Adaptation (LoRA) nổi lên như một kỹ thuật mang tính đột phá, được giới thiệu trong một bài báo của Edward J [9]. Hu và nhóm của mình vào năm 2021. Nó đóng băng các trọng số ban đầu của LLMs và tích hợp các ma trận cấp thấp có thể huấn luyện mới vào từng lớp của kiến trúc Transformers. Cách tiếp cận này không chỉ làm giảm số lượng tham số có thể huấn luyện mà còn giảm thời gian huấn luyện và nguồn lực tính toán cần thiết, từ đó đưa ra giải pháp thay thế hiệu quả hơn cho việc tinh chỉnh mô hình.

LoRA sử dụng khái niệm phân rã ma trận thứ hạng thấp. Về cơ bản, LoRA phân tích một ma trận thành ba ma trận riêng biệt, một trong số đó là ma trận đường chéo lưu trữ các giá trị nhỏ. Các giá trị đơn lẻ này có vai trò then chốt vì chúng đánh giá tầm quan trọng của các chiều khác nhau trong ma trận, với các giá trị lớn hơn biểu thị tầm quan trọng cao hơn và các giá trị nhỏ hơn biểu thị tầm quan trọng thấp hơn.




Hình 3.2. Phân rã giá trị số ít của ma trận $m \times n$

Cách tiếp cận này cho phép LoRA duy trì các đặc tính thiết yếu của dữ liệu trong khi giảm kích thước, từ đó tối ưu hóa quy trình tinh chỉnh. LoRA can thiệp vào quá trình này, đóng băng tất cả các tham số mô hình ban đầu và đưa ra một cặp “ma trận phân rã thứ hạng” cùng với các trọng số ban đầu. Những ma trận nhỏ hơn này, ký hiệu là A và B, trải qua quá trình huấn luyện thông qua học tập có giám sát.

Yếu tố then chốt trong chiến lược này là tham số được gọi là thứ hạng ('r'), cho biết kích thước của ma trận thứ hạng thấp. Việc lựa chọn 'r' phù hợp có thể mang lại kết quả tốt, ngay cả với giá trị nhỏ hơn, từ đó tạo ra ma trận cấp thấp với ít tham số cần huấn luyện hơn. Chiến lược này đã được triển khai hiệu quả bằng cách sử dụng các thư viện nguồn mở như HuggingFace Transformers, tạo điều kiện tinh chỉnh LoRA cho nhiều tác vụ khác nhau với hiệu quả vượt trội.

Ví dụ về sử dụng LoRA trong huấn luyện các mô hình sử dụng Transformers. Thay vì đưa toàn bộ tham số (biểu diễn ở 32 bit) vào huấn luyện thì LoRA biểu diễn chúng dưới dạng 16 bit, chọn ra những tham số cần tác động và đưa vào huấn luyện. Như vậy bộ nhớ biểu diễn tham số được giảm đi rất nhiều. Cùng với giảm kích thước biểu diễn tham số, số lượng tham số được đưa vào tinh chỉnh cũng được giảm bớt. Chính vì vậy thời gian của quá trình tinh chỉnh được giảm đáng kể.



Hình 3.3. So sánh kỹ thuật huấn luyện LLMs

3.3.3. Prompt Engineering

Các mô hình ngôn ngữ lớn hoạt động như một hộp đen đã được huấn luyện trên một tập dữ liệu cực kỳ lớn, nó nhận vào một đoạn văn bản và trả về một đoạn văn bản khác dưới dạng phản hồi. Có nghĩa là, kết quả mà các mô hình này trả về hoàn toàn phụ thuộc vào văn bản mà ta đưa vào cho nó.

Prompt Engineering chính là một kỹ thuật giúp điều chỉnh các yếu tố trong đoạn văn bản đầu vào để tối ưu hóa đầu vào và khai thác tối đa hiệu quả của LLMs mà ta nhận được qua câu trả lời của các LLMs. Một số kỹ thuật prompt engineering đơn giản và dễ thấy nhất, chính là cung cấp ngữ cảnh trong đầu vào, hay thêm một số điều kiện và ràng buộc cho đầu ra mà ta muốn nhận được. Bằng việc hiểu rõ và sử dụng các kỹ thuật prompt engineering, ta có thể định hình đầu ra mong muốn, chọn lọc các thông tin và tùy biến LLMs để thực hiện nhiều loại nhiệm vụ nhất định.

Thành phần của một prompt có thể bao gồm:

Yêu cầu – Instruction: Là những hướng dẫn hay chính xác là những gì bạn muốn các LLMs trả về. Nguyên tắc của hướng dẫn là càng chi tiết càng tốt.

Vai trò – Role: Các LLMs là những mô hình ngôn ngữ đa năng, nhưng đôi khi việc đa năng này là không cần thiết khi hỏi về một lĩnh vực nhất định. Vì vậy, ta cần cho nó một vai trò để giới hạn lĩnh vực của nó. Điều này cũng tương tự như việc khi ta muốn hỏi về sức khỏe ta sẽ tìm đến bác sĩ hay khi muốn hỏi về luật ta sẽ tìm đến luật sư.

Ngữ cảnh – Context: Đây là phần cung cấp nhiều thông tin hơn cho LLMs, tại phần này bổ sung những thông tin về câu trả lời mà LLMs cần tạo ra, cách suy nghĩ và phân tích...

Chỉ thị đầu ra (Output indicator): Là phần định hình cho kết quả mong muốn nhận được từ LLMs. Phần này sẽ cung cấp các thông tin liên quan tới hình thức, cách trả lời, độ dài, mức độ chi tiết...

Một số kỹ thuật Prompt Engineering:

Zero-shot learning: Là kỹ thuật không đưa hoặc đưa ra rất ít những thông tin định hướng cho câu trả lời của LLMs.

**You**

"đó là một trải nghiệm rất khủng khiếp"
cảm nghĩ:

**ChatGPT**

Cảm giác của tôi là sự sợ hãi và lo lắng. Có thể đó là một trải nghiệm đầy ám ảnh hoặc đáng sợ, gây ra những cảm xúc tiêu cực và làm cho người trải qua cảm thấy rất không thoải mái hoặc sợ hãi.

**You**

"đó là một trải nghiệm rất khủng khiếp"
Mục đích:

**ChatGPT**

Mục đích của câu này có thể là để diễn đạt cảm xúc của người nói về một trải nghiệm mà họ đã trải qua và cảm thấy rất không mong muốn, khó chịu hoặc đau đớn. Điều này có thể được sử dụng để cảnh báo người khác về tình trạng hoặc sự kiện tiêu cực mà họ có thể gặp phải, hoặc đơn giản chỉ để chia sẻ cảm xúc của bản thân với người khác.



Hình 3.4. Kỹ thuật Zero-shot

Few-shot Learning: Là kỹ thuật đưa ra một hoặc nhiều mẫu câu trả lời cho cùng một câu hỏi với các tập dữ liệu khác nhau; từ đó LLMs sẽ hiểu được ý định và cấu trúc của câu trả lời và trả lời một cách phù hợp.

Chain-of-thoughts: Là kỹ thuật chỉ cho LLMs chi tiết từng bước phân tích và đưa ra câu trả lời.

**You**

Is the sum of the following numbers an odd number? 129, 295, 925, 229

No

Is the sum of the following numbers an odd number? 222, 13, 87, 61

Yes

Is the sum of the following numbers an odd number? 35, 76, 91, 38

No

Is the sum of the following numbers an odd number? 14, 93, 12, 35

**ChatGPT**

To determine whether the sum of the given numbers is odd or even, we simply need to add them up and then check if the sum is odd or even.

1. Sum of 129, 295, 925, 229 = $129 + 295 + 925 + 229 = 1578$ (even)

Answer: No

2. Sum of 222, 13, 87, 61 = $222 + 13 + 87 + 61 = 383$ (odd)

Answer: Yes

3. Sum of 35, 76, 91, 38 = $35 + 76 + 91 + 38 = 240$ (even)

Answer: No

4. Sum of 14, 93, 12, 35 = $14 + 93 + 12 + 35 = 154$ (even)

Answer: No



Hình 3.5. Kỹ thuật Few-shot

Một số kỹ thuật Prompt Engineering nâng cao khác như: Generated Knowledge Prompting, Tree of thoughts, Retrieval Augmented Generation (RAG).

3.3.4. VectorDB

Như chúng ta đã biết thông tin tồn tại dưới nhiều hình thức; một số thông tin không có cấu trúc như tài liệu văn bản, nội dung đa phương tiện, âm thanh. Những đổi mới trong trí tuệ nhân tạo và máy học cho phép chúng ta tạo ra mô hình nhúng để đáp ứng yêu cầu lưu trữ những dạng dữ liệu như vậy. Các phần nhúng mã hóa tất cả các loại dữ liệu thành véc-tơ để nắm bắt ý nghĩa và ngữ cảnh của tài liệu. Điều này cho phép chúng ta tìm tài liệu tương tự bằng cách

tìm kiếm các điểm dữ liệu lân cận. Phương pháp tìm kiếm véc-tơ mang lại trải nghiệm độc đáo như chụp ảnh bằng điện thoại thông minh và tìm kiếm hình ảnh tương tự.

Cơ sở dữ liệu véc-tơ cung cấp khả năng lưu trữ và truy xuất véc-tơ dưới dạng điểm đa chiều. Cơ sở dữ liệu véc-tơ thêm nhiều tính năng bổ sung giúp tra cứu hiệu quả và nhanh chóng các điểm lân cận gần nhất trong không gian N chiều. Thông thường, cơ sở dữ liệu véc-tơ được hỗ trợ bởi các chỉ mục lân cận k gần nhất (k -NN) và được xây dựng bằng các thuật toán như Hierarchical Navigable Small World (HNSW) và Inverted File Index (IVF). Nó cũng cung cấp nhiều tính năng bổ sung như quản lý dữ liệu, khả năng chịu lỗi cao, xác thực và kiểm soát quyền truy cập và công cụ truy vấn.

Một số cơ sở dữ liệu dùng để lưu trữ véc-tơ Embedding được sử dụng rộng rãi như:

Milvus: Là một cơ sở dữ liệu véc-tơ mã nguồn mở miễn phí để lưu trữ và tìm kiếm các véc-tơ ở quy mô lớn. Milvus hỗ trợ nhiều kỹ thuật lập chỉ mục, bao gồm IVF và HNSW, đồng thời có hiệu suất cực nhanh;

Pinecone: Là một cơ sở dữ liệu véc-tơ với nhiều tính năng, thân thiện với lập trình viên cũng như dễ dàng mở rộng;

ChromaDB: Cơ sở dữ liệu véc-tơ mã nguồn mở dễ sử dụng và tích hợp sâu rộng với hệ sinh thái Python;

pgVector: Là phần mở rộng của cơ sở dữ liệu PostgreSQL mạnh mẽ, cho phép xử lý và đánh chỉ mục các loại dữ liệu véc-tơ bằng các thuật toán như HNSW hoặc IVFFlat;

Facebook AI Similarity Search (Faiss): Thư viện của Meta cho phép các nhà phát triển nhanh chóng tìm kiếm các phần nhúng của các tài liệu đa phương tiện tương tự nhau;

Ngoài ra các nhà cung cấp dịch vụ đám mây phổ biến cũng đều có cơ sở dữ liệu véc-tơ của riêng mình như OpenSearch của AWS, AlloyDB của Google Cloud hoặc Cognitive Search của Azure.

Giới thiệu về ChromaDB:


Trong những cơ sở dữ liệu hỗ trợ lưu trữ cũng như truy xuất véc-tơ embedding; ChromaDB nổi lên là một mã nguồn mở dễ dàng sử dụng cũng như được hỗ trợ mạnh mẽ bởi Python. Trong phần này sẽ trình bày chi tiết quá trình cài đặt và sử dụng ChromaDB cho bài toán tạo cơ sở dữ liệu lưu trữ véc-tơ embedding cũng như truy xuất các véc-tơ từ cơ sở dữ liệu sử dụng ngôn ngữ Python, Langchain, OpenAI và Google Colab.

Chuẩn bị dữ liệu:

Để bắt đầu, thực hiện tải các tệp tài liệu lên thư mục đã chọn. Các tệp tài liệu này có thể là bất kỳ tệp nào, nhưng phần hướng dẫn này Tôi sẽ sử dụng các file txt từ TechCrunch được lưu trữ trong thư mục https://www.dropbox.com/s/vs6ocyvpzzncvwh/new_articles.zip và được giải nén lên thư mục “new_articles” trên Driver. Cũng có thể sử dụng các loại tệp khác, chẳng hạn như tệp PDF hoặc tệp Markdown. Khi tải xong có thể cần phân chia dữ liệu thành các phần nhỏ hơn để thuận tiện cho việc xử lý.

Thực thi câu lệnh:

```
[4] !wget -q https://www.dropbox.com/s/vs6ocyvpzzncvwh/new_articles.zip  
!unzip -q new_articles.zip -d '/content/drive/MyDrive/DeAnTotNghiep/ChromaDB/new_articles'
```




Cài đặt và thiết lập môi trường:



Load dữ liệu:

Load dữ liệu từ drive cho quá trình chunk các đoạn văn bản. Bước này sẽ thực hiện tải toàn bộ các tệp dữ liệu có trong thư mục new_articles đã tải lên từ bước trước.



Phân đoạn dữ liệu:

Việc phân đoạn dữ liệu được hỗ trợ bởi hàm RecursiveCharacterTextSplitter. Hàm này sẽ thực hiện chia nhỏ văn bản thành các đoạn nhỏ gọi là “chunk”. Kích thước của mỗi chunk phụ thuộc vào tham

số `chunk_size` và `chunk_overlap`. Kích thước, độ phức tạp của mỗi đoạn ảnh hưởng tới quá trình embedding, huấn luyện mô hình cũng như thông tin từ mỗi đoạn.

```
[ ] #splitting the text into
    text_splitter = RecursiveCharacterTextSplitter(chunk_size=1000, chunk_overlap=200)
    texts = text_splitter.split_documents(documents)
```

Embeddings:

Dữ liệu sau khi được chia nhỏ thành các đoạn sẽ được nhúng thành các véc-tơ.

```
# Embed and store the texts
persist_directory = '/content/drive/MyDrive/DeAnTotNghiep/ChromaDB/db'

embedding = OpenAIEmbeddings()


vectordb = Chroma.from_documents(documents=texts,
                                 embedding=embedding,
                                 persist_directory=persist_directory)
```

WARNING:chromadb:Using embedded DuckDB with persistence: data will be stored in: db

Lưu trữ véc-tơ:

Thực hiện lưu `vectordb` vào driver.

```
[ ] # persiste the db to disk
    vectordb.persist()
    vectordb = None
```



Tải cơ sở dữ liệu đã được lưu trước đó từ drive

```

0s [21] # Now we can load the persisted database from disk, and use it as normal.
vectordb = Chroma(persist_directory=persist_directory,
                  embedding_function=embedding)

```

Tìm kiếm ngữ nghĩa:

```

0s [22] # create the chain to answer questions
qa_chain = RetrievalQA.from_chain_type(llm=OpenAI(),
                                      chain_type="stuff",
                                      retriever=retriever,
                                      return_source_documents=True)

/usr/local/lib/python3.10/dist-packages/langchain_core/_api/deprecation.py:117: LangChainDeprecationWarning: The class `langchain_community.llms.openai.OpenAI` is deprecated.
warn_deprecated(

0s [23] ## Cite sources
def process_llm_response(llm_response):
    print(llm_response['result'])
    print('\n\nSources:')
    for source in llm_response["source_documents"]:
        print(source.metadata["source"])

0s [24] # full example
query = "How much money did Pando raise?"
llm_response = qa_chain(query)
process_llm_response(llm_response)

/usr/local/lib/python3.10/dist-packages/langchain_core/_api/deprecation.py:117: LangChainDeprecationWarning: The function `__call__` was deprecated in L
warn_deprecated(
Pando raised $30 million in a Series B round, bringing its total raised to $45 million.

```

3.3.5. Kỹ thuật RAG

Như đã đề cập ở những mục trên, để các LLMs có thể trả lời được các câu hỏi liên quan đến thông tin của doanh nghiệp; chúng ta cần tiến hành tinh chỉnh chúng dựa trên cấu trúc câu hỏi và kết quả trả lời. Phương pháp này có ưu điểm cho kết quả chính xác. Tuy nhiên, việc tinh chỉnh không chỉ đòi hỏi chi phí lớn về phần cứng cũng như thời gian để huấn luyện là một thách thức không nhỏ đối với các doanh nghiệp vừa và nhỏ. Trong nhiều trường hợp, khi dữ liệu doanh nghiệp thay đổi dẫn đến cần phải huấn luyện lại mô hình; đây cũng là hạn chế chính của giải pháp tinh chỉnh mô hình. Hạn chế này được khắc phục bằng kỹ thuật RAG kết hợp với Prompt nhằm cung cấp thông tin ngữ cảnh cho các LLMs sử dụng để trả lời.

3.3.5.1. Tổng quan

RAG là cụm từ viết tắt của Retrieval-Augmented Generation, đây là kỹ thuật giúp nâng cao khả năng của mô hình sinh ngôn ngữ (Language Model Generation) kết hợp với tri thức bên ngoài (External Knowledge).

Phương pháp này thực hiện theo nguyên lý: khi người dùng đưa ra một câu hỏi thì hệ thống sẽ truy vấn cơ sở dữ liệu (cơ sở dữ liệu lưu trữ các đoạn văn bản và véc-tơ nhúng của chúng) để tìm các đoạn văn bản có khoảng cách ngữ nghĩa gần với câu hỏi; các đoạn văn bản này sẽ được sử dụng để cung cấp thông tin cho LLMs đưa ra câu trả lời. Phương pháp này được gọi là trả lời dựa trên ngữ cảnh và chúng ta sử dụng công nghệ Prompt để chỉ dẫn cho LLMs.


Như vậy, trước khi sử dụng RAG cần tạo một cơ sở dữ liệu véc-tơ để lưu trữ tất cả thông tin của doanh nghiệp. Thông tin của doanh nghiệp sẽ được chia thành các khối (chunk), ngữ nghĩa của mỗi khối được xác định bởi một véc-tơ embedding. Việc xây dựng véc-tơ embedding có một ý nghĩa quan trọng trong truy xuất chính xác thông tin ngữ cảnh cho câu hỏi. Điều này hoàn toàn có thể được thực hiện tương đối dễ dàng dựa trên các mô hình ngôn ngữ Sentences-Transformers đã được huấn luyện trên đa ngôn ngữ như: “all-mpnet-base-v2”, “all-MiniLM-L6-v2”...

Ngoài ra, để xác định khoảng cách ngữ nghĩa của câu hỏi với các chunk thông qua các véc-tơ embedding tương ứng; có thể sử dụng các dạng chuẩn trong toán học để đo khoảng cách của các véc-tơ embedding. Một số độ đo thường được sử dụng như Cosine, khoảng cách Euclid, tích chập. Mặt khác chúng ta cũng cần hệ quản trị cơ sở dữ liệu hỗ trợ việc lưu trữ véc-tơ embedding cũng như các truy vấn trên chúng. Hiện nay có rất nhiều hệ quản trị cơ sở dữ liệu hỗ trợ véc-tơ embedding và kỹ thuật RAG, trong phạm vi đề án này sử dụng Hệ quản trị cơ sở dữ liệu ChromaDB.

3.3.5.3. Quá trình hoạt động của RAG

Qua trình của RAG được chia thành 2 phần chính:


1. Quá trình xây dựng cơ sở dữ liệu véc-tơ:



Hình 3.6. Quá trình tạo VectorDB

Bước này sẽ thực hiện chuyển đổi toàn bộ dữ liệu thành các véc-tơ và lưu trữ chúng vào một cơ sở dữ liệu véc-tơ. Thực hiện các bước chia nhỏ toàn bộ dữ liệu thành các đoạn nhỏ. Sử dụng mô hình nhúng để embedding các đoạn thành các véc-tơ và cuối cùng lưu trữ các véc-tơ vào cơ sở dữ liệu véc-tơ.

2. Quá trình sử dụng cơ sở dữ liệu véc-tơ:



Hình 3.7. Sơ đồ quá trình sử dụng VectorDB

Quá trình này được thực hiện qua các bước sau:

1. Embedding câu hỏi của người dùng:

Sử dụng Embedding LLMs để embedding câu hỏi của người dùng thành véc-tơ và chuyển sang giai đoạn tiếp theo.

2. Tìm kiếm ngữ nghĩa:

Cơ chế Retrieval quét toàn bộ véc-tơ trong cơ sở dữ liệu để xác định các phân đoạn tri thức nào có ngữ nghĩa tương đồng với câu truy vấn của người dùng ở mức độ cao. Các đoạn này sau đó được đưa vào LLMs để làm tăng ngữ cảnh cho quá trình sinh ra câu trả lời.

3. Tạo prompt:

Các đoạn văn bản đã lấy sau quá trình Retrieval từ cơ sở dữ liệu được kết hợp với câu hỏi ban đầu của người dùng để tạo thành một prompt; sau đó được chuyển cho LLMs để sinh câu trả lời.

4. Sinh câu trả lời:

LLMs sinh câu trả lời dựa trên prompt nhận được và trả về cho người dùng.

3.3.5.4. Ưu điểm của RAG

Với RAG, LLMs có thể tận dụng dữ liệu bên ngoài để cung cấp tri thức cho mô hình;

RAG không yêu cầu huấn luyện lại mô hình, tiết kiệm thời gian và tài nguyên tính toán;

Hiệu quả ngay cả với một lượng dữ liệu hạn chế;

Tuy nhiên, RAG cũng có nhược điểm đó là hiệu suất của RAG phụ thuộc vào chất lượng độ chính xác của mô hình Retrieval; tính toàn diện và chính xác của kho tri thức có sẵn;

RAG phù hợp nhất cho các tình huống có nhiều dữ liệu chưa được gán nhãn và ít dữ liệu đã được gán nhãn.

RAG lý tưởng cho các ứng dụng như trợ lý ảo, chatbot: Các trợ lý ảo, chatbot, như Siri hay Alexa cần lấy thông tin từ nhiều nguồn khác nhau để trả lời các câu hỏi khác nhau trong thời gian thực. Chúng cần hiểu câu hỏi, lấy thông tin liên quan và sau đó đưa ra câu trả lời mạch lạc và chính xác;

Cần truy cập theo thời gian thực vào thông tin cụ thể như hướng dẫn sử dụng: Đây là một ví dụ về trường hợp mà RAG đặc biệt hữu ích. Khi bạn hỏi trợ lý ảo một câu hỏi cụ thể, chẳng hạn như "Làm thế nào để reset điều khiển ABC". RAG trước tiên sẽ truy xuất thông tin liên quan từ hướng dẫn sử dụng sản phẩm hoặc các tài liệu khác, sau đó sử dụng thông tin đó để tạo ra câu trả lời rõ ràng, ngắn gọn.

Tóm lại, các mô hình RAG rất phù hợp cho các ứng dụng có sẵn nhiều thông tin nhưng không được tổ chức hay gán nhãn phù hợp cho mô hình có thể học.

3.4. HỆ THỐNG ĐÔNG Á CHATBOT

Trong bối cảnh công nghệ AI ngày càng phát triển và được ứng dụng sâu rộng trong cuộc sống, công việc, đặc biệt là trong tự động hóa. Hơn nữa Trường đại học Công nghệ Đông Á là một cơ sở giáo dục có uy tín, đang trên con đường phát triển, là đơn vị đào tạo ra các trí thức cho tương lai; việc ứng dụng công nghệ thông tin đặc biệt là AI vào các hoạt động quản lý, học tập, nghiên cứu khoa học của Trường là điều tất yếu.

Việc trả lời các câu hỏi về Trường Đại học Công nghệ Đông Á vẫn chủ yếu dựa vào nguồn thông tin từ các chuyên viên tư vấn tuyển sinh, trợ lý học tập, nguồn thông tin từ trang web của trường. Tuy nhiên, cần nhận ra rằng phương pháp truy cập thông tin này có một số hạn chế và bất tiện, đặc biệt khi số lượng câu hỏi và số lượng người cần truy cập cũng như cường độ truy cập tăng lên đáng kể hoặc khi người dùng cần truy cập vào các thông tin cụ thể từ hệ thống văn bản của trường. Những vấn đề chính về sự cần thiết của việc triển

khai một ChatBot để giải quyết các câu hỏi về Trường Đại học Công nghệ Đông Á:

- Tăng cường khả năng phục vụ: ChatBot có thể cung cấp dịch vụ phục vụ liên tục 24/7, giúp đáp ứng nhanh chóng và hiệu quả các câu hỏi của người dùng, bất kể thời gian và địa điểm.

- Giảm áp lực cho nhân viên và tự động hóa quy trình: Bằng cách chuyển giao một số nhiệm vụ phổ biến và lặp đi lặp lại cho ChatBot, nhân viên có thể dành thời gian và tập trung vào các nhiệm vụ khác quan trọng hơn. Đồng thời, việc tự động hóa quy trình trả lời câu hỏi cũng giúp giảm thiểu sai sót và tăng hiệu suất làm việc;

- Tiết kiệm thời gian và tăng trải nghiệm người dùng: Người dùng có thể dễ dàng và nhanh chóng tìm kiếm thông tin cần thiết về trường mà không cần phải tìm kiếm trên trang web hoặc chờ đợi phản hồi từ nhân viên;

- Mở rộng phạm vi phục vụ: ChatBot có thể xử lý đồng thời nhiều câu hỏi từ nhiều người dùng khác nhau, từ đó mở rộng phạm vi phục vụ và tối ưu hóa quá trình tương tác.

- Cung cấp thông tin chi tiết và chính xác: ChatBot có thể truy xuất thông tin từ hệ thống văn bản của trường và cung cấp thông tin chi tiết và chính xác về quy chế, quy định, khóa học, chương trình đào tạo, học phí và nhiều thông tin khác;

- Tạo trải nghiệm tương tác hấp dẫn: ChatBot có thể được thiết kế để tương tác với người dùng một cách thân thiện và hấp dẫn trên nhiều nền tảng khác nhau, tạo ra trải nghiệm tương tác tốt và thu hút người dùng truy cập.

Trên cơ sở những lý do trên, việc triển khai một ChatBot để trả lời các câu hỏi về Trường Đại học Công nghệ Đông Á sẽ là một giải pháp hiệu quả để cải thiện dịch vụ, tăng trải nghiệm người dùng và tối ưu hóa quy trình làm việc

của nhân viên, cải thiện chất lượng phục vụ người học đồng thời nâng cao vị thế của nhà Trường.

3.4.1. Thu thập và tiền xử lý dữ liệu

Thu thập dữ liệu từ nguồn tin cậy:

- Trang web chính thức của Trường Đại học Công nghệ Đông Á tại địa chỉ <https://eaut.edu.vn/>. Việc thực hiện thu thập dữ liệu từ website của trường được thực hiện qua các bước, cụ thể:

- + Duyệt qua các trang và chuyên mục chính trên website.
- + Lưu trữ các bài viết, thông báo, và tin tức có liên quan đến lịch sử, sứ mệnh, các chương trình đào tạo, hoạt động nghiên cứu, và sự kiện của trường.
- + Sử dụng công cụ trích xuất dữ liệu tự động để lấy các thông tin liên quan đến các câu hỏi thường gặp và tư vấn tuyển sinh.
- + Dữ liệu được lưu vào file text.

- Tài liệu văn bản chính thức của trường bao gồm: quyết định thành lập trường, văn bản hành chính, quy chế, quy định, tài liệu kiểm định chất lượng... Việc thực hiện thu thập dữ liệu từ văn bản của trường được thực hiện qua các bước:

- + Thu thập các tài liệu dưới dạng PDF hoặc Word từ bộ phận hành chính của trường.
- + Sử dụng phần mềm OCR (Optical Character Recognition) để chuyển đổi các tài liệu dạng ảnh hoặc PDF sang văn bản có thể xử lý được.
- + Lưu trữ các tài liệu đã xử lý trong cơ sở dữ liệu để dễ dàng truy cập và phân tích.

- Tài liệu tư vấn tuyển sinh, các câu hỏi thường gặp trong tư vấn tuyển sinh. Việc thu thập được thực hiện qua các bước:

- + Liên hệ với phòng tư vấn tuyển sinh để lấy các tài liệu và thông tin chính thức.

+ Duyệt qua các tài liệu tư vấn tuyển sinh, bao gồm các brochure, tờ rơi, và các bài viết trên website tuyển sinh.

+ Thu thập và tổng hợp các câu hỏi thường gặp từ các kênh tư vấn trực tuyến và trực tiếp.

Kết quả dữ liệu thu thập được:

- Các quyết định thành lập trường và các văn bản hành chính quan trọng;
- File text thông tin về ban giám hiệu;
- File text thông tin về xứ mạng, mục tiêu, tầm nhìn;
- File text thông tin về định hướng phát triển;
- File text thông tin về ba công khai;
- File text thông tin về linh vật;
- File text thông tin về Tuyển sinh đại học, thạc sỹ, quy chế tuyển sinh;
- File text thông tin về các hệ đại học, văn bằng chứng chỉ
- File text thông tin về chương trình đào tạo các ngành Quản trị kinh doanh, Tài chính kế toán, Du lịch, Cơ khí, Nhiệt – Điện lạnh, Công nghệ thực phẩm, Xây dựng, Điện - Điện tử, công nghệ thông tin, Dược, Điều dưỡng, Luật và Ngôn ngữ;
- File text thông tin về Nghiên cứu khoa học, hợp tác quốc tế;
- File text thông tin về việc làm, học bổng;
- Quy chế và quy định của trường;
- Tài liệu kiểm định chất lượng và các báo cáo đánh giá;
- Câu hỏi thường gặp của học sinh và phụ huynh liên quan đến tuyển sinh, học phí, học bổng, và các cơ hội nghiên cứu;
- Thông tin về các sự kiện truyền thông, hội thảo, và các hoạt động ngoại khóa;
- Thông tin liên hệ và cách thức tham gia các sự kiện của trường.

Tiền xử lý dữ liệu. Việc xử lý dữ liệu được thực hiện qua các bước, sử dụng các công cụ, cụ thể như sau:

Bước 1: Tập hợp, tổ chức dữ liệu

Dữ liệu thu thập được ở bước trước được chia thành các folder, file theo từng chuyên đề, loại dữ liệu.

Bước 2: Chuyển đổi định dạng tệp

Các tệp dữ liệu doc, docx, pdf, excel được chuyển đổi về dạng txt.

Công cụ: PyMuPDF, pdfminer.six, python-docx.

Bước 3: Làm sạch và chuẩn hóa văn bản

Loại bỏ các ký tự đặc biệt, khoảng trắng thừa, và chuẩn hóa văn bản để đảm bảo dữ liệu sạch và nhất quán.

Công cụ: Python, re (regular expressions), nltk (Natural Language Toolkit).

Bước 4: Phân đoạn dữ liệu

Dữ liệu được phân đoạn thành các đoạn nhỏ hơn như câu, đoạn ngắn mô tả về một thông tin của trường.

Công cụ: Python, nltk, spacy.

Bước 5: Tạo Embeddings cho Văn bản

Chuyển đổi văn bản thành các vector embeddings để sử dụng trong VectorDB và các mô hình ngôn ngữ.

Công cụ: transformers (thư viện Hugging Face).

Bước 6: Lưu trữ trong VectorDB


Lưu trữ các vector embeddings và văn bản gốc trong VectorDB để dễ dàng truy vấn và sử dụng.

Công cụ: ChromaDB.

3.4.2. Kiến trúc hệ thống ChatBot

Dựa trên các kết quả thử nghiệm, các công trình nghiên cứu được công bố bởi cộng đồng LLM (huggingface), và điều kiện cơ sở cũng như nhu cầu của Đại học Công nghệ Đông Á; Học viên đề xuất sử dụng mô hình trả lời câu hỏi có số lượng tham số dưới 10 tỷ (10B). Đây là những mô hình ngôn ngữ có kích thước nhỏ nhưng độ chính xác tương đối cao, đáng kể nhất là hai mô hình mã nguồn mở: “LlaMa2-7B” và “Mistral-7B”.

Kết quả so sánh giữa Mistral-7B và LlaMa2-7B đã chỉ ra rằng Mistral-7B có tốc độ suy luận nhanh hơn, độ chính xác cũng cao hơn trong việc trả lời các câu hỏi dựa trên ngữ cảnh, tuy nhiên nó kém hơn LlaMa2-7B trong việc trả lời về viết mã. Tuy nhiên, mục tiêu xây dựng hệ thống ChatBot của Đại học Công nghệ Đông Á là để tự động giải đáp các câu hỏi liên quan đến nhiều lĩnh vực hoạt động của nhà Trường nên Học viên đã lựa chọn Mistral-7B cho hệ thống này. Cụ thể hơn, sau bước huấn luyện ban đầu mô hình Mistral-7B, các nhà cung cấp đã tiến hành tinh chỉnh trên 3 triệu câu hỏi thông thường bằng tiếng Anh để nhận được mô hình Mistral-7B-Instruct-v0.2 với cấu trúc Prompt là: `<s> [INS] Question? [/INS] Answer </s>`. Sau khi đã đánh giá thực nghiệm Mistral-7B-Instruct-v0.2 đối với ngữ cảnh tiếng Việt thì cho kết quả khá chính xác và đáp ứng được bài toán.



Hình 3.8. Kiến trúc hệ thống Đông Á Chatbot

Ví dụ về quy trình hoạt động của chatbot:

- Người dùng đưa ra câu hỏi “Ai là Hiệu trưởng Đại học Đông Á?”. Chatbot tự động tìm kiếm trong cơ sở dữ liệu đã tạo trước đó. Giả sử tìm được chunk gần nhất: “Hôm nay trường Đại học Công nghệ Đông Á bổ nhiệm ông Nguyễn Văn A giữ chức vụ Hiệu trưởng”.

- Kết hợp giữa chunk nhận được và câu hỏi để tạo ra prompt với định dạng như sau:

<s> [INS]

“Bạn là ChatBot trả lời các câu hỏi dựa trên ngữ cảnh.

Context: “Hôm nay trường Đại học Công nghệ Đông Á bổ nhiệm ông Nguyễn Văn A giữ chức vụ Hiệu trưởng”.

Question: “Ai là Hiệu trưởng Đại học Công nghệ Đông Á?”

[/INS]

- Chatbot sử dụng mô hình “Mistral-7B-Instruct-v0.2” sinh ra câu trả lời “Ông Nguyễn Văn A là Hiệu trưởng Trường Đại học Công nghệ Đông Á”.

Toàn bộ hệ thống Chatbot được xây dựng trên một máy tính Workstation với GPU có dung lượng bộ nhớ tối thiểu là 11GB giống như RTX 2080 Ti. Để hệ thống chạy nhanh hơn chúng ta cần trang bị một số GPU mới giống như H100 có dung lượng bộ nhớ 80G với giá bán khoảng \$25,000.

3.4.3. Kết quả thử nghiệm

Dữ liệu dùng cho chatbot: Qua quá trình thu thập và tiền xử lý dữ liệu; kết quả đã tổng hợp được hầu hết các tài liệu, văn bản chính thức của trường và thông tin trên website của trường. Từ đó sử dụng dữ liệu dưới dạng văn bản này embedding và lưu vào cơ sở dữ liệu véc-tơ của chatbot.


Mã chương trình chatbot: bao gồm 2 module:

- Module embedding và tạo cơ sở dữ liệu véc-tơ


- Module chatbot: tiếp nhận chuỗi câu hỏi của người dùng, tìm kiếm ngữ nghĩa trên cơ sở dữ liệu, trả về câu trả lời cho người dùng;

- Giao diện giao tiếp với người dùng: cho phép người dùng nhập câu hỏi và hiển thị câu trả lời trên nền tảng web.

Một số hình ảnh kết quả thử nghiệm:



Hình 3.9. Kết quả câu hỏi về tổ chức lớp sinh viên



Hình 3.10. Kết quả câu hỏi về ngành công nghệ thông tin của trường

3.4.4. Đánh giá độ chính xác của chatbot

Để đảm bảo chatbot hoạt động hiệu quả và cung cấp thông tin chính xác, cần phải thực hiện các phương pháp đánh giá độ chính xác một cách toàn diện. Dưới đây là các bước và phương pháp đánh giá đề án đã thực hiện:

Mục tiêu của việc đánh giá:

Đánh giá độ chính xác, tính nhất quán, và hiệu quả của chatbot trong việc trả lời các câu hỏi liên quan đến Trường Đại học Công nghệ Đông Á.

Tiêu chí đánh giá:

Độ chính xác: Mức độ đúng đắn của câu trả lời so với thông tin đã được thu thập và lưu trữ.

Tính nhất quán: Khả năng của chatbot trong việc đưa ra các câu trả lời nhất quán cho cùng một câu hỏi trong các thời điểm khác nhau.

Chuẩn bị dữ liệu đánh giá:

Dữ liệu đánh giá: Tạo bộ dữ liệu gồm 100 câu hỏi mẫu và câu trả lời dựa trên các tệp văn bản đã thu thập, bao gồm:

- Câu hỏi về các quyết định thành lập trường và văn bản hành chính.
- Câu hỏi về thông tin ban giám hiệu, sứ mạng, mục tiêu, tầm nhìn, định hướng phát triển, ba công khai, và linh vật.
- Câu hỏi về tuyển sinh, chương trình đào tạo, nghiên cứu khoa học, hợp tác quốc tế, việc làm, học bổng, quy chế, quy định, và tài liệu kiểm định chất lượng.
- Câu hỏi thường gặp của học sinh và phụ huynh.

Thực hiện đánh giá thủ công:

Bước 1: Sử dụng các câu hỏi đã chuẩn bị trước đó (50 câu) đưa vào chatbot và ghi nhận câu trả lời của chatbot.

Bước 2: Đối chiếu câu trả lời của chatbot với câu trả lời trong tài liệu thu thập được và ghi nhận tỷ lệ trả lời đúng của chatbot với từng câu hỏi.

Đánh giá tự động:

Bước 1: Sử dụng chương trình Python với các thư viện như nltk, scikit-learn, và transformers để hỏi chatbot với 50 câu hỏi đã chuẩn bị trước đó.

Bước 2: ghi nhận các chỉ số Precision, Recall, F1-score, và BLEU score trên từng câu hỏi.

Kết quả:

- Phương pháp thủ công:

Độ chính xác: đánh giá chatbot đạt mức độ chính xác khoảng 95% trong việc trả lời các câu hỏi.

Tính nhất quán: Đánh giá cho thấy chatbot duy trì tính nhất quán cao, với tỷ lệ nhất quán trên 98%.

Mức độ hữu ích: Phản hồi từ nhóm chuyên gia cho thấy các câu trả lời của chatbot hữu ích và đáp ứng được yêu cầu thông tin của người dùng. Điểm trung bình về mức độ hữu ích đạt 4.5/5.

- Phương pháp tự động:

- + Điểm Precision: 0.9
- + Điểm Recall: 0.95
- + Điểm F1-score: 0.9
- + Điểm BLEU score: 0.9

Các chỉ số này cho thấy chatbot có khả năng cung cấp câu trả lời đúng và phù hợp với ngữ cảnh trong đa số trường hợp. Tuy nhiên để đưa chatbot vào áp dụng thực tế cần có bước kiểm tra với người dùng cuối để ghi nhận mức độ hài lòng của người dùng cuối với câu trả lời của chatbot từ đó điều chỉnh tham số của mô hình để đạt hiệu quả tối ưu nhất.

KẾT LUẬN

Trong quá trình thực hiện đề án, tôi đã khảo sát nhu cầu cũng như thực trạng các giải pháp đang được áp dụng để tra cứu, tìm hiểu thông tin về trường Đại học Công nghệ Đô Á từ đó đánh giá hiệu quả của các giải pháp hiện có. Tìm hiểu về học sâu, kiến trúc Transformers cũng như quy trình huấn luyện mạng hồi quy và các lý thuyết liên quan.

Đề án cũng tìm hiểu và trình bày phương pháp huấn luyện, tinh chỉnh các LLMs cùng với đó đã nêu những thách thức trong huấn luyện LLMs. Trình bày các kỹ thuật nâng cao hiệu suất như tối ưu hóa bộ nhớ, giảm độ phức tạp tính toán và Prompt Engineering nhằm khắc phục và giải quyết những thách thức trong huấn luyện LLMs cho bài toán Chatbot.

Tôi đã nghiên cứu lý thuyết và thực hành về VectorDB, kỹ thuật Prompt Engineering và Retrieval-Augmented Generation (RAG) vào xây dựng Chatbot về tra cứu tìm hiểu thông tin về trường Đại học Công nghệ Đông Á. Đề án đã trình bày quá trình xây dựng Chatbot từ thu thập, tiền xử lý dữ liệu, xây dựng kiến trúc Chatbot và một số kết quả thử nghiệm Chatbot.

Tuy nhiên do điều kiện phần cứng (GPU) của Đại học Công nghệ Đông Á đang trong quá trình xây dựng nên hệ thống Chatbot đã chưa được triển khai ở thời điểm báo cáo. Dữ liệu dùng cho Chatbot chưa cập nhật được đầy đủ do quy định về bảo mật thông tin của Trường. Trong thời gian tới khi hạ tầng phần cứng của Trường được hoàn thiện Chatbot sẽ được triển khai và đi vào sử dụng thực tế thay thế và bổ sung cho các giải pháp hiện tại góp phần nâng cao trải nghiệm của cộng đồng EAUT. Chatbot của đề án có thể được điều chỉnh và cập nhật thông tin cho bất kỳ một trường, doanh nghiệp nào cần một hệ thống trả lời tự động, hiệu quả và nhanh chóng.

TÀI LIỆU THAM KHẢO

Tiếng Việt

- [1] Đại học Công Nghệ Đông Á (2008), *Website Đại học Công nghệ Đông Á*, truy cập ngày, tại trang web <https://eaut.edu.vn/>.
- [2] IRENDER VIET NAM JSC (2020), *Giới thiệu một số Deep Learning Frameworks phổ biến*, truy cập ngày, tại trang web <https://irender.vn/gioi-thieu-mot-so-deep-learning-frameworks-pho-bien/>.
- [3] Vũ Hữu Tiếp (2022), *Machine Learning cơ bản*, machinelearningcoban.com.
- [4] Nguyễn Thanh Tuấn (2019), *Deep learning cơ bản*, NTTUAN8.COM.

Tiếng Anh

- [5] Sebastian Ruder (2016), "An overview of gradient descent optimization algorithms", *arXiv preprint arXiv:1609.04747*.
- [6] Charu C Aggarwal (2018), "Neural networks and deep learning", *Springer*. 10(978), tr. 3.
- [7] Antonio Gulli Amita Kapoor, Sujit pal (2022), *Deep learning with tensorflow and keras*, Packt Publishing Ltd.
- [8] Christopher Olah (2015), "Understanding lstm networks".
- [9] Amir Shevat (2017), *Designing bots: Creating conversational experiences*, " O'Reilly Media, Inc."
- [10] Wikipedia (2021), *Cơ sở dữ liệu MNIST*, truy cập ngày, tại trang web https://wiki.scholarship.edu.vn/C%C6%A1_s%E1%BB%9F_d%E1%B%AF_li%E1%BB%87u_MNIST.